

湖南大学



变点监测视角下呼叫中心动态排队模型的优化分析

课程名称: 工程优化方法

姓 名: 李 梅

学 号: B2402Z0104

2025 年 8 月 27 号

目录

1 模型设计	3
1.1 研究问题	3
1.2 模型构建	4
1.2.1 呼叫中心排队网络模型	4
1.2.2 离线与在线联合的两阶段人员配置优化模型	5
2 实例分析	9
2.1 问题描述	9
2.2 数据分析	10
2.3 呼叫中心坐席人员的离线全局优化	11
2.3.1 外部客户到达率的离线变点监测	12
2.3.2 排队网络相关指标分析	15
2.3.3 坐席人员的配置优化	16
2.4 呼叫中心坐席人员的在线局部调整	19
2.4.1 外部客户到达率的在线变点监测	19
2.4.2 坐席人员的在线调整	22
3 结论	24

1 模型设计

1.1 研究问题

日常生活中，有很多排队现象，例如在超市收银、银行的业务办理、医院挂号等场景，排队论就是对这些服务系统中常见的排队问题进行相关研究的理论，主要是对客户到达过程、服务过程以及排队规则进行研究，计算并分析性能指标，如客户等待时间、排队队长、服务强度等。通过分析这些性能指标，排队论可以为服务资源的配置优化、系统运营效率的提升提供科学的理论依据。值得注意的是，排队论的理论分析通常基于系统达到稳态这一前提条件。

但在现实生活中，客户到达率通常会随时间或受各种不确定因素的影响发生动态变化，例如客户到达率在某一阶段骤增，此时传统的静态人员配置方案可能无法满足需求，导致客户等待时间增加、流失率上升，同时服务人员将面临工作强度超负荷问题。因此，如何根据客户到达的随机性来合理配置服务人员，这对呼叫中心等服务系统的平稳运营至关重要。

随着呼叫中心的广泛普及和规模的不断扩大，为有效优化呼叫中心的人员配置策略，平衡客户满意度和运营成本，本文选择呼叫中心这一典型的排队系统进行一系列优化研究。

首先，分析其现实情况下的服务流程以及特点，构建一类非平稳呼叫中心排队网络模型。其次，提出一种基于贝叶斯变点监测与梯度优化的两阶段人员配置优化模型，促使呼叫中心的人员配置效果在离线全局最优和在线局部最优之间取得平衡。在第一阶段，基于历史数据使用贝叶斯离线变点监测来分析客户到达率的变点，并据此对客户到达过程进行合理分段。在此基础上，采用梯度优化方法得到初步的人员配置方案，使得系统总成本最小化。此阶段的优化策略以离线全局最优为目标，为后续在线优化奠定基础。第二阶段基于实时数据流，采用贝叶斯在线变点监测方法动态识别异常变点，进而灵活调整第一阶段的人员配置策略，如客户到达率突然增大时临时调配兼职人员或者客户到达率骤降时移除冗余服务人员，实现单位时间的总成本最小化。

本文的优化模型与传统的单阶段优化模型相比，更具有灵活性，人员配置方案更为合理，可以实现离线全局最优与在线局部最优的平衡，有效提升呼叫中心的水平，降低其运营成本。

1.2 模型构建

1.2.1 呼叫中心排队网络模型

呼叫中心的服务流程大致可以分为 2 个阶段：第一阶段是客户拨号进入 IVR 自助语音系统，并根据自助语音的提示进行操作。在此过程中，客户能够在完全自助的模式下获得所需服务，不需要排队等候；第二阶段是客户在 IVR 系统未完成所需服务，则会选择人工服务。

在众多研究中，呼叫中心的人工服务阶段常被视为单节点服务系统，即假设客户的每次呼叫仅对应一次服务。然而在实际情况中，呼叫中心客户的呼入往往涉及多次服务，即客户在发起呼叫后可能提出多种服务需求。考虑坐席人员对业务的熟悉程度不一或者客户的服务需求超出当前坐席人员的职责范围，初次接待服务的坐席人员在完成其服务后，可能会根据客户的服务要求将呼叫转接到对应业务的坐席人员继续进行服务。因此，在人工服务阶段，多节点的服务系统更加贴近现实情况，即客户发起呼叫后，按其所需服务类型被分配给相应坐席，如果此时该坐席人员处于繁忙状态，则客户需要进行等待直到坐席空闲为止。服务完成后，根据客户需求，继续转接到其他坐席接受服务，或服务完成离开系统。考虑客户在 IVR 服务过程中不需要等待，本文聚焦人工服务阶段，选取某一类服务的服务流程构建排队网络模型并研究其优化问题。

现以某一类服务需求为起始点，根据服务流，按照先到先服务原则，建立排队网络模型，如图 1-1 所示。假设系统共有 N 个节点，具有某类服务需求的客户首先进入人工服务节点 1 接受此服务，服务完成后按需进入其他人工服务节点，随后选择继续接受服务或离开系统。假设客户在节点 i 完成服务后，以概率 r_{ij} 进入节点 j ，($i, j=1,2,\dots,N$)，以概率 r_{i0} 离开排队网络，满足概率之和为 1；并且在每个节点 i ，有 x_i 个相同坐席（服务台）在进行服务，每个坐席的服务强度均为 ρ_i 。进一步假设该网络中服务系统的容量是无限的，客户至少从一个节点离开排队网络且该网络中没有吸收状态节点，则可知， $I - R$ 可逆。




图 1-1 呼叫中心排队网络模型

1.2.2 离线与在线联合的两阶段人员配置优化模型

本节主要阐述呼叫中心人员配置优化模型以及两阶段优化流程。在呼叫中心服务系统中，客户希望得到高效服务以尽可能减少等待，而呼叫中心则追求在一定的客户满意度下使得服务成本最低，因此，如何平衡客户等待队长和呼叫中心服务成本成为业界和学术界关心的重要问题。本文综合考虑客户的等待成本和呼叫中心的运营成本，构建人员配置优化模型。在单个服务台的服务强度固定的情况下，单位时间内的总成本可表示为：

$$\tilde{V} = \sum_{i=1}^N \left[x_i \cdot \rho_i \cdot c_i^f(\rho_i) + EL_i \cdot c_i^w(x_i) \right] \quad (1-1)$$


其中， $c_i^f(\rho_i)$ 表示在节点 i ，每个服务台单位时间内提供服务而产生的成本，其表示为服务强度的函数； $c_i^w(x_i)$ 表示单位时间内节点 i 的队列中每位客户的等待成本，在单个服务台的服务强度固定的情况下，队长与服务台的数量相关，故将等待成本表示为服务台数量 x_i 的函数； L_i 为节点 i 的队长。

现实情况下，外部客户到达率通常是动态变化的，具有时变特征，这给系统的优化带来了挑战。对于具有时变外部客户到达率的排队系统，学者们经常采用分段逼近的方式研究其优化问题，但以往分段通常采用固定划分的形式。基于此，本文采用更加灵活的分段方法，即利用贝叶斯方法对外部客户到达率的变点先后进行离线与在线监测，根据变点位置对到达过程进行分段，进一步研究其优化。如图 1-1 所

示，本文只需考虑节点 1 处外部客户到达率的变点。用表示在 λ_1 时刻的外部客户到达率，用 λ_{1t_i} 表示 t_i 时刻到达系统的人数，构建客户到达分布 $F(y_{t_i}, \lambda_{1t_i})$ 多变点模型：

$$y_{t_i} \sim F(y_{t_i}, \lambda_{1t_i}), i = 1, 2, \dots, n. \quad (1-2)$$


图 3-2 为客户到达分布多变点模型示意图。从图 3-2 可以清晰地了解到，离线变点监测通过客户到达的历史数据，得到 k 个变点，其位置分别为 $s_1, s_2, \dots, s_k$ ，规定 $s_0 = 0, s_{k+1} = n$ 。变点时刻分别在 $t_{s_1}, t_{s_2}, \dots, t_{s_k}$ ； k 个变点将 n 个时刻划分为 $k+1$ 个时段，每个时段表示为 $T_j (j = 1, 2, \dots, k+1)$ ；每段外部到达率相等，记为 λ_{1T_j} 。在线变点监测阶段以 2 个异常变点为例进行分析，即通过输入客户到达的实时数据流，得到 2 个异常变点，位置在 s_i'', s_i' ，异常变点时刻 $t_{s_i''}, t_{s_i'}$ 。根据异常变点得到异常变点时段 T_i' ，且 $\lambda_{1T_i'} \neq \lambda_{1T_j}$ ， $\lambda_{1T_j} = \lambda_{1T_{j(1)}} = \lambda_{1T_{j(2)}}$ 。除异常变点外，其余变点的位置及其他参数与离线变点监测结果相同。



1-2 客户到达分布多变点模型

本文根据贝叶斯估计原理，先后采用离线与在线方法对客户到达率的变点进行监测。第一阶段根据客户到达的历史数据，采用离线方法对一天内外部客户到达率的变点进行监测，根据变点对客户到达过程进行分段，进一步以客户和呼叫中心的总成本最小化为目标设置各时段人员配置策略；第二阶段在第一阶段人员配置方案的基础上，收集现场实时数据，对客户到达率的变点进行在线监测，针对突发情况进行预警，并以异常变点时段内单位时间总成本最小化为目标进行二次人员优化，保障服务水平。

综上，本文构建的非平稳呼叫中心排队网络的监测和优化流程如图 1-3 所示。



1-3 人员配置优化流程

在第一阶段中，以一天内呼叫中心与客户总成本最小化为目标，进行全局人员配置优化，即确定变点后，结合单位时间的总成本函数式(3.1)，得出呼叫中心人员配置优化模型：

$$\min \sum_{j=1}^{k+1} \sum_{i=1}^N \left[x_{iT_j} \cdot \rho_{iT_j} \cdot c_{iT_j}^f(\rho_{iT_j}) + EL_{ij} \cdot c_{ij}^w(x_{iT_j}) \right] \cdot T_j \quad (1-3)$$

其中， $\rho_i = \gamma_{iT_j} / x_{iT_j} \mu_i$ ， γ_{iT_j} 为各节点的实际到达率。

第二阶段人员配置优化以第一阶段优化方案为基础，根据客户到达的异常情况，增加临时调度成本，以异常变点时段单位时间内的总成本最小化为目标进行在线局部优化，使得呼叫中心与客户总成本在离线全局最优和在线局部最优之间达到平衡。假设在异常变点时段 T'_i ，节点 i 的最优人员配置数量为 x'_i ，离线优化方案中节点 i 的最优人员配置数量为 x_i ，此时异常变点时段的单位时间成本 $\bar{V}$ 在式(1-1)的基础上增加了在线人员调整成本，具体形式为：

$$\bar{V} = \sum_{i=1}^N \left[x'_i \cdot \rho_i \cdot c_i^f(\rho_i) + EL_i \cdot c_i^w(x'_i) + c_s(x_i - x'_i)^+ + c_r(x'_i - x_i)^+ \right] \quad (1-4)$$

其中， $(x_i - x'_i)^+ = \max\{(x_i - x'_i), 0\}$ ， $(x'_i - x_i)^+ = \max\{0, x'_i - x_i\}$ ，且 c_s 为单位人员过剩成本，若离线阶段配置的坐席人员数量 x_i 多于在线阶段实际需要的坐席人员数量 x'_i ，则将过剩坐席人员移除，此时产生人员过剩成本 $c_s(x_i - x'_i)^+$ ； c_r 为单位人员不足成本，若离线阶段的坐席人员数量少于在线阶段的实际需要，则在在线阶段需要临时调配灵活坐席人员，此时产生人员不足成本 $c_r(x'_i - x_i)^+$ 。

因此，第二阶段即在线阶段确定异常变点后的呼叫中心人员配置优化模型可表示成如下形式：

$$\min \sum_{i=1}^N \left[x'_i \cdot \rho_i \cdot c_i^f(\rho_i) + EL_i \cdot c_i^w(x'_i) + c_s(x_i - x'_i)^+ + c_r(x'_i - x_i)^+ \right] \quad (1-5)$$

在优化过程中，为获得最优的服务人员配置策略，本文选用 Adam 优化算法进

行数值求解，Adam 算法属于梯度优化算法，计算效率高，收敛速度快。具体步骤如下：

第一阶段：离线变点监测与人员配置

步骤 1 基于历史数据，根据贝叶斯原理，使用 RJMCMC 算法确定外部客户到达率的变点个数；

步骤 2 利用 MCMC 方法进行模拟，得到外部客户到达率的变点位置 s_i 及各时段外部到达率 λ_{T_j} 的贝叶斯估计值，对客户到达过程进行分段处理；

步骤 3 计算各节点实际到达率 γ_{iT_j} ：每个时段 T_j 内，各节点实际到达率满足：

$$\gamma_{T_j} = \lambda_{T_j}(I - R)^{-1} \quad (1-6)$$

其中， λ_{T_j} 为时段 T_j 内各节点外部客户到达率构成的向量， γ_{T_j} 为时段 T_j 内各节点实际到达率构成的向量， $R = (r_{ij})_{N \times N}$ 为客户在各节点之间的转移概率矩阵；

步骤 4 在一天内总成本最小约束下，使用梯度下降优化算法求解式(3.3)得到排队网络中各节点的最优人员配置数量。

第二阶段：在线变点监测与实时人员调整

步骤 1 根据客户到达的实时数据，利用贝叶斯在线变点监测算法对客户到达过程进行实时监测，即通过计算运行长度的后验概率来确定客户到达率的变点，将监测结果与第一阶段的变点进行对比，发现异常变点；

步骤 2 在第一阶段分段的基础上，根据第二阶段的变点监测结果对分段进行更新，计算异常变点处各节点实际到达率 $\gamma_{iT'_i}$ ；

步骤 3 在第一阶段人员配置的基础上，使用梯度下降优化算法求解式(1-5)，对异常时段 T'_i 各节点的服务人员进行在线调整，使得单位时间的总成本最小化。

2 实例分析

为验证模型的适用性，本章将模型应用于实际案例研究中，对美国某银行的呼叫中心服务系统进行优化研究。首先对真实数据进行描述与分析，其次选取一类服务的服务流程建立排队网络模型，最后利用前文构建的基于贝叶斯离线与在线变点监测的两阶段人员配置优化模型进行优化研究，对呼叫中心等服务系统如何制定合适的服务人员配置策略具有一定的现实指导意义。

2.1 问题描述

美国某银行的呼叫中心主要提供零售、消费贷款、商业、网上银行等多种类型的服务，每天处理多达 30 万个呼叫，这些呼叫大部分都是在 IVR 结束，但也有 7 万多次呼叫继续寻求人工服务。基于本文建立的排队网络模型，本文只考虑该呼叫中心人工服务阶段的数据集进行实例分析，数据集包含了每位发起呼叫客户的详细信息，以及从客户发起呼叫到所有服务完成期间的全过程数据。

现随机选取该呼叫中心 2002 年 4 月的数据进行研究，首先对该数据进行清洗与预处理，然后根据前文建立的排队网络对该呼叫中心的服务流程进行梳理，最终筛选出研究所需指标并对其进行解释说明，主要包含以下指标：

- (1) call-id：与整个呼叫相关联的通用标识符；
- (2) wait-time：等待时间，即客户接受服务前的等待时间；
- (3) service-group：正在处理呼叫的服务组；
- (4) service：呼叫处理的服务类型，包括 Retail 服务，Consumer Loans 服务，Telesales 服务等多种服务类型；
- (5) first-service：呼叫者向坐席请求的第一种服务类型；
- (6) service-time：服务时间，即客户接受服务所需时间；
- (7) segment-start：子呼叫段启动的时间；
- (8) segment-end：子呼叫段结束的时间；
- (9) seg-type：呼叫的状态，具体包括：开始状态、中间状态和结束状态。

根据本文建立的排队网络模型，现选用 2002 年 4 月数据集中的一组服务进行研究，其服务流程为：在人工服务阶段，客户首先在坐席组 1 办理 Retail 业务，服务完成后继续在坐席组 2 办理 Consumer Loans 业务或在坐席组 3 办理其他业务随后选

择继续接受服务或者离开呼叫系统。根据数据的实际情况，建立如下排队络模型，如图 2-1 所示。




图 2-1 美国某银行呼叫中心排队网络模型

2.2 数据分析

现统计 2002 年 4 月该呼叫中心每日的客户到达量，进而得到该月客户到达量的日变化情况，如图 2-2 所示。




图 2-2 2002 年 4 月 Retail 服务节点客户到达量

由图 2-2 可以看出，客户到达具有一定的周期性，每周同一时期的客户到达量

大致相同且工作日期间的客户到达数量明显高于周末期间的客户到达数量。这与美国银行的工作时间密切相关，工作日期间即周一至周五客户会集中进行业务的办理，因此会保持相对较高的到达率。而周六周天为休息日，相关业务也会停止办理，客户发起的人工呼叫量也会随之减少。这些客户会集中到周一进行人工服务的办理，因此周一会出现骤增的客户到达数量。

本文主要研究坐席人员的优化配置，考虑客户到达的周期性特征以及银行休息日。现随机选取 4 月第 1 周工作日即 4 月 1 日至 4 月 5 日期间的相关数据来研究该周工作日期间的客户到达规律，我们分析一天内 00:00-24:00 每小时到达的客户人数占每日总数的百分比来更清晰地了解客户到达分布，如图 2-3 所示。




图 2-3 2002 年 4 月 1-5 日 Retail 服务节点客户到达特征

根据图 2-3，我们可以很明显的看出工作日期间每天客户到达数量的分布几乎是相同的，例如高峰时段 10:00-11:00 期间的到达率大约是平时每小时的 2.5 倍，而且客户集中在工作时间进行呼叫。因此，我们选取 2002 年 4 月 2 日的 08:00-18:00 期间的相关数据进行研究，共计 704 位客户从其发起呼叫到所有服务完成期间的全过程数据，根据这些数据研究客户到达率的变化特征，并进一步研究排队网络的人员配置优化问题。

2.3 呼叫中心坐席人员的离线全局优化

本节主要通过分析客户到达的周期性规律来确定呼叫中心未来运营所需的服务能力，对坐席人员的配置进行初步优化，即对该呼叫中心排队网络中的相关历史数

据进行分析，采用离线贝叶斯变点监测方法寻找外部客户到达率的变点，根据变点对客户到达过程分段，进而优化各时段中的坐席人员配置策略。

2.3.1 外部客户到达率的离线变点监测

首先对排队网络的外部客户到达分布进行研究。现对 2002 年 4 月 2 日 08:00-18:00 期间排队网络的外部客户到达数据进行整理分析，设置时间间隔长度为 5 分钟，得到外部客户到达数据共计 120 个 ($n = 120$)，各时段数量变化如图 2-4 所示。




图 2-4 2002 年 4 月 2 日 08:00-18:00 各时段外部客户到达数量

分析图 2-4 可知，外部客户到达率在一天内具有明显波动性，在 13:00 前后外部客户的到达率变化明显，因此本文将 2002 年 4 月 2 日的 08:00-18:00 的外部客户到达数据分为 08:00-13:00,13:00-18:00 两段，分别对其进行泊松分布检验，检验结果如表 2-1 所示。

表 4-1 08:00-18:00 客户到达过程 K-S 检验结果

		08:00-13:00	13:00-18:00
N		60	60
泊松参数	平均值	6.400	17.283
最极端差分	绝对	0.081	0.142
	正	0.081	0.129
	负	-0.067	-0.142
柯尔莫哥洛夫-斯米洛夫 Z		0.628	1.100
渐进显著性（双尾）		0.825	0.178

a.检验分布为泊松分布

b.根据数据计算

根据表 2-1 的检验结果，各时段的 P 值均大于 0.05，表明客户到达过程符合泊松过程。因此，分段后的排队系统在每个时段内均表现出逐段平稳的特性，可以使用泊松分布进行拟合。

现采用贝叶斯离线变点监测方法来寻找排队网络外部客户到达率的变点。设定初始值 $k = 1$, $s_1 = 60$, $\lambda_{1T_j} (j = 1, 2)$ 分别取初始分段上的均值，超参数 $k_{max} = 5$, $b = 60$, $a = 25/4$ 。首先根据 RJMCMC 算法得到变点个数估计直方图，如图 2-5 所示。




图 2-5 变点个数估计直方图

根据图 2-5 可知， $k = 2$ 时变点个数的后验概率最大，故外部客户到达率在一天

内发生了 2 次明显变化， $\hat{k} = 2$ 。接下来利用 MCMC 算法进行模拟，变点位置的后验密度分布如图 2-6 所示，各时段外部客户到达率的后验密度分布如图 2-7 所示，各参数的估计值见表 2-2。





图 2-6 变点位置后验密度

图 2-7 外部客户到达率后验密度

表 2-2 参数的贝叶斯估计

参数	s_1	s_1	λ_{1T_1}	λ_{1T_2}	λ_{1T_3}
----	-------	-------	------------------	------------------	------------------

估计值	60.023	107.682	1.147	3.516	1.663
-----	--------	---------	-------	-------	-------

分析图 2-6、图 2-7 以及表 2-2 可知，外部客户到达的变点位置在 60 以及 108 附近，即变点时刻在 13:00、17:00，3 个时段外部客户到达率（人/min）的估计值分别为 $\widehat{\lambda_{1T_1}} = 1.147$ ， $\widehat{\lambda_{1T_2}} = 3.516$ ， $\widehat{\lambda_{1T_3}} = 1.663$ 。因此，我们根据离线变点监测的结果将一天分为 08:00-13:00、13:00-17:00、17:00-18:00 三段进行分析。

2.3.2 排队网络相关指标分析

根据变点监测得到的分段结果，我们对排队网络中的相关指标进行分析。首先对各节点间的转移概率进行估计。现实生活中各个客户之间通常彼此独立，在此我们假设排队网络中各个客户的选择相互独立，排队规则采用先到先服务的等待制，且通常情况下认为呼叫中心的容量无限。鉴于各节点的服务时间表现出相对稳定性，可合理假设服务时间分布近似于负指数分布。结合以上假设，我们可以利用开排队网络的性质对相关指标进行计算分析。

下面给出转移概率 r_{12} 估计的详细过程。令 X_{12} 表示客户在节点 1 完成服务后，对节点 2 的选择，即：

$$X_{12} = \begin{cases} 1, & \text{进入节点 2} \\ 0, & \text{其他} \end{cases} \quad (2-1)$$

结合图 2-1 可知， X_{12} 服从参数为 r_{12} 的二点分布，即 $X_{12} \sim B(1, r_{12})$ 。现在采用极大似然法对转移概率 r_{12} 进行估计，假设样本观测值为 $x_{12}^{(1)}, x_{12}^{(2)}, \dots, x_{12}^{(n)}$ ，得到对数似然函数：

$$\ln L(r_{12}) = \sum_{m=1}^n x_{12}^{(m)} \ln r_{12} + \left(n - \sum_{m=1}^n x_{12}^{(m)} \right) \ln (1 - r_{12}) \quad (2-2)$$

对式(2-2)进行求导，得：

$$\frac{\partial \ln L(r_{12})}{\partial r_{12}} = \frac{\sum_{m=1}^n x_{12}^{(m)}}{r_{12}} - \frac{n - \sum_{m=1}^n x_{12}^{(m)}}{1 - r_{12}} = 0 \quad (2-3)$$

由此得到转移概率 r_{12} 的估计值 $\widehat{r}_{12}$ ：

$$\widehat{r}_{12} = \frac{1}{n} \sum_{m=1}^n x_{12}^{(m)} = \bar{x}_{12} \quad (2-4)$$

现根据 2002 年 4 月 2 日 08:00-18:00 期间到达该呼叫中心的客户在三个节点转移的实际数据，得到节点 1 转移情况的样本数据，样本数据详情见科学数据银行。由式(2-4)和样本数据表，可得 $\widehat{r}_{12} = 0.2798$ ；同理，可得其他节点间转移概率的估计

值，结果见表 2-3。

表 2-3 转移概率估计值

转移概率	$\widehat{r}_{12}$	$\widehat{r}_{13}$	$\widehat{r}_{23}$	$\widehat{r}_{20}$	$\widehat{r}_{32}$	$\widehat{r}_{30}$
估计值	0.2798	0.7202	0.0457	0.9543	0	1

对于客户的实际到达率，我们根据表 2-3 中各节点转移概率的估计值及表 2-2 中排队网络各时段外部客户到达率的估计值，得到各时段中客户在各节点的实际到达率，具体见表 2-4。

表 2-4 实际到达率 γ_{iT_j} （人/min）

	08:00-13:00	13:00-17:00	17:00-18:00
节点 1	1.147	3.516	1.663
节点 2	0.321	0.984	0.165
节点 3	0.841	2.577	1.219

接下来，我们通过 2002 年 4 月 2 日当天该呼叫中心排队网络中各节点的平均服务时间来衡量各节点坐席人员的服务速率（人/min），具体见表 2-5。由于数据的获取权限，我们对排队网络中各节点初始坐席人员的配置情况进行假设，以服务系统的稳态为标准进行设置，具体见表 2-5。

表 2-5 系统参数值

参数	μ_1	μ_2	μ_3	x_{1T_j}	x_{2T_j}	x_{3T_j}
取值	0.276	0.235	0.137	18	9	24

2.3.3 坐席人员的配置优化

根据外部客户到达率的变点监测结果可知，各节点在不同时段，客户的实际到达率差别较大，如果一天内各节点的人员配置情况不变，结合服务率等参数，可以得到变点前后排队系统的性能指标，具体见表 2-6。

表 2-6 优化前指标

		08:00-13:00	13:00-17:00	17:00-18:00
节点 1	x_{1T_j}	18	18	18
	ρ_{1T_j}	0.231	0.708	0.335
	EL_{1T_j}	2.580	5.010	1.821
节点 2	x_{2T_j}	9	9	9
	ρ_{2T_j}	0.152	0.465	0.220
	EL_{2T_j}	0.298	0.450	0.000
节点 3	x_{3T_j}	24	24	24
	ρ_{3T_j}	0.256	0.784	0.371
	EL_{3T_j}	1.243	3.672	0.000
总成本		332259.916		

分析表 2-6 可知，服务强度和平均等待队长受到达率影响变化明显，总成本为 332259.916 美元。而且，当客户到达率增大时，对坐席人员的需求也会增大，此时原有的坐席人员数量较少，无法满足客户的需求，导致平均等待队长增大；当客户到达率减少时，对坐席人员的需求减少，导致服务人员大多处于空闲状态，造成资源浪费。因此，有必要根据外部客户到达率的变化合理配置服务人员的数量，对服务系统进行优化，进而平衡客户等待成本与呼叫中心的服务成本。

接下来，根据第一章建立的人员配置优化模型对各节点的坐席人员数量进行优化，目标函数即：

$$V = \sum_{j=1}^{k+1} \sum_{i=1}^3 \left[\left[\alpha \cdot \left(\frac{\gamma_{iT_j}}{x_{iT_j} \mu_i} \right)^2 + \beta \cdot \exp \left(\sigma \cdot \frac{\gamma_{iT_j}}{x_{iT_j} \mu_i} + \theta \right) + \delta \cdot \frac{\gamma_{iT_j}}{x_{iT_j} \mu_i} + \varepsilon \cdot x_{iT_j} \right] \cdot T_j \right. \\ \left. \cdot \frac{\gamma_{iT_j}}{\mu_i} + EL_{iT_j} \cdot \left(c_0 + \frac{\gamma_{iT_j}}{\mu_i} \cdot \frac{\tilde{k}}{x_{iT_j}} \right) \right]$$

其中，为了方便分析，待定成本系数依然设置为 $\alpha = 0.4, \beta = 0.5, \sigma = 2.5, \delta = 0.8$ ，常数 $\theta = 1.25$ ，待定系数 $\varepsilon = 0.68, \tilde{k} = 20$ 。对于固定成本，由于数据的获取权限，2002 年该呼叫中心相关的成本数据无法获取。因此，本文参考美联储经济数据库(FRED)提供的数据，2023 年美国人均可支配收入约为 63668 美元，美国法定工作时间为 40

小时/周，根据上述数据对人均收入进行折算，得到固定成本 $c_0 \approx 0.51$ 美元/分钟。

按照人员配置优化模型，利用前文改进的 Adam 算法对目标函数进行优化， x_{iT_j} 的初始值见表 2-5，得到最优人员配置策略。总成本优化过程见图 2-8。




图 2-8 总成本优化过程

由图 2-8 可知，在优化过程中总成本随着迭代次数增加逐渐降低，最终稳定在 27.5 万美元附近。优化后的服务人员配置策略及相关指标见表 2-7。

表 2-7 优化后指标

		08:00-13:00	13:00-17:00	17:00-18:00
节点 1	x_{1T_j}	11	21	13
	ρ_{1T_j}	0.378	0.607	0.463
	EL_{1T_j}	0.002	0.037	0.007
节点 2	x_{2T_j}	5	10	6
	ρ_{2T_j}	0.273	0.419	0.330
	EL_{2T_j}	0.005	0.009	0.009
节点 3	x_{3T_j}	13	28	16
	ρ_{3T_j}	0.472	0.672	0.556

EL_{3T_j}	0.010	0.068	0.029
总成本	274577.391		

分析图 2-8 和表 2-7 可知，呼叫中心总成本在该人员配置策略下达到最小，即 274577.391 美元，可见对系统进行优化后，总成本减少约 17.36%。同时，对比优化前后各指标，可知当各节点到达率明显增大时，通过调节服务人员数量，系统内的平均等待人数有所减少，服务人员的工作负荷也得到缓解；当各节点到达率减少时，通过调节服务人员数量，服务人员的利用率也得到有效提升，避免了服务资源的浪费，客户等待成本与服务成本得到有效平衡，实现了总成本最小化，有利于呼叫中心系统的平稳运营。因此，基于贝叶斯离线变点监测的初始人员配置模型能够为现实情况下服务系统的优化决策提供理论依据与指导，具有良好的适用性。

2.4 呼叫中心坐席人员的在线局部调整

上文我们对该呼叫中心的人员配置策略进行了离线全局优化。但在现实生活中，客户的到达有时因突发情况产生骤降或猛增的趋势，此时初始优化方案可能失效。因此，第二阶段的优化在第一阶段人员配置方案的基础上，根据现场实际情况进行在线调整。

2.4.1 外部客户到达率的在线变点监测

通过前文对数据的统计分析，并未发现该呼叫中心客户到达的突发事件。因此，考虑在线优化的特点，本节构造类似客户到达率突增场景，即对排队系统中外部客户到达的异常情况进行假设来分析第二阶段的人员配置优化问题。现假设在 2.3 节离线变点监测结果的基础上，客户到达率在当天 09:00 突发紧急情况，导致外部客户到达率突然由 1.147 人/min 增大到 5 人/min，并且在 12:00 恢复到正常情况，即 1.147 人/min。其他时段并未发生异常情况，具体参数见表 2-8。

表 2-8 参数设置

参数	取值	参数	取值
k	4	$T_{1(1)}$	08:00-09:00
s_1''	12	$T_{1'}$	09:00-12:00

s_1'	48	$T_{1(2)}$	12:00-13:00
s_1	60	T_2	13:00-17:00
s_2	108	T_3	17:00-18:00
t_{s_1}''	09:00	$\lambda_{1T_{1(1)}}$	1.147
t_{s_1}'	12:00	$\lambda_{1T_1'}$	5
t_{s_1}	13:00	$\lambda_{1T_{1(2)}}$	1.147
t_{s_2}	17:00	λ_{1T_2}	3.516
		λ_{1T_3}	1.163

注：粗体为第二阶段与第一阶段相比变化的参数。

现在进行贝叶斯在线变点监测，使用伽马先验对客户到达率进行建模，输入客户到达率相关的先验参数，通过基于贝叶斯方法的在线变点监测模型来对节点 1 处的外部客户到达率进行在线变点监测，输出变点信息，可视化结果如图 2-9 所示。




图 2-9 在线变点监测结果

分析图 2-9 知，与第一阶段的离线变点监测结果相比，第二阶段即在线阶段在第 10 个数据点附近开始发生异常情况，外部客户到达率突然增大，之后在第 45 个数据点附近恢复正常。在线变点监测得到的变点信息如表 2-9 所示。

表 2-9 在线变点监测结果

参数	k	s_1'	s_1''	s_1	s_2
估计值	4	11	48	60	108

分析表 2-9 可知，变点的具体位置在 11、48、60、108 附近，将在线变点监测结果表 2-9 与第一阶段的离线变点监测结果表 2-2 进行对比，可以得出第二阶段的异常变点在第 11、48 个数据附近，即外部客户到达率在 08:50 发生异常，并在 12:00 恢复正常。根据我们的假设即表 2-8 中的异常变点位置，可知在线变点监测不仅能准确识别异常变点并能提前进行预警。下文中，我们以在线变点监测结果为标准进行分析，即对异常时段 08:50-12:00 的人员配置方案进行优化。

现对异常变点前后的到达率进行分析，可知节点 1 处的外部客户到达率在 08:50 由第一阶段监测到的 1.147 人/min 突增到 5 人/min，并在 12:00 恢复，即外部客户到达率在 12:00 由 5 人/min 恢复到第一阶段监测到的 1.147 人/min。根据第一阶段的优化结果表 2-7 可知，在异常时段节点 1、2、3 的坐席人员的数量分别为 11、5、13，各节点的服务率不变，具体见表 2-5，各节点转移概率不变，具体见表 2-3。现对该异常时段 08:50-12:00 相关的排队系统指标进行计算并与第一阶段优化后的指标进行对比，结果见表 2-10。

表 2-10 异常变点前后系统指标

08:50-12:00	节点 1		节点 2		节点 3	
	第 1 阶段优	第 2 阶段异	第 1 阶段优	第 2 阶段异	第 1 阶段优	第 2 阶段异
	化后	常	化后	常	化后	常
$\gamma_{1T_1'}$	1.147	5	0.321	1.399	0.841	3.664
$x_{1T_1'}$	11	11	5	5	13	13
$\rho_{1T_1'}$	0.378	1.647	0.273	1.191	0.472	2.057
$EL_{1T_1'}$	0.002	——	0.005	——	0.010	——

分析表 2-10 可知，在第一阶段优化后的服务人员配置策略下，当服务系统中外部客户到达发生异常变化，由 1.147 人/min 时增加到 5 人/min 时，各节点客户的实际到达率随之增大，受其影响，各节点的服务强度增加，3 个服务节点均处于非稳态，

系统处于饱和状态，队长将无限增大。此时如果不及时进行在线调整，呼叫中心将面临严重损失。因此，需对异常时段 08:50-12:00 期间坐席人员的配置策略进行在线调整，使得单位时间内的总成本最小，达到局部最优状态。

2.4.2 坐席人员的在线调整

现在对具体的优化方案进行分析，面对客户突增的异常情况，应立刻调配兼职人员到岗来缓解排队系统中的拥堵现象，降低单位时间内的客户等待成本与呼叫中心服务成本，使二者达到相对均衡状态。第二阶段依然采用 08:50-12:00 期间各节点的最优人员配置策略，目标函数式为：

$$V = \sum_{i=1}^3 \left[\left[\alpha \cdot \left(\frac{\gamma_{iT_j}}{x'_{iT_j} \mu_i} \right)^2 + \beta \cdot \exp \left(\sigma \cdot \frac{\gamma_{iT_j}}{x'_{iT_j} \mu_i} + \theta \right) + \delta \cdot \frac{\gamma_{iT_j}}{x'_{iT_j} \mu_i} + \varepsilon \cdot x'_{iT_j} \right] \cdot \frac{\gamma_{iT_j}}{\mu_i} + EL_{iT_j} \cdot \left(c_0 + \frac{\gamma_{iT_j}}{\mu_i} \cdot \frac{\tilde{k}}{x'_{iT_j}} \right) + c_s (x_{iT_j} - x'_{iT_j})^+ + c_r (x'_{iT_j} - x_{iT_j})^+ \right]$$

其中，相关系数仍为第一阶段的值，即 $\alpha = 0.4, \beta = 0.5, \sigma = 2.5, \delta = 0.8, \theta = 1.25, c_0 = 0.51, \varepsilon = 0.68, \tilde{k} = 20$ ；异常变点发生第 1 时段，故 $T_j = T_1$ ；人员过剩成本与人员不足成本同上文，即 $c_r = 0.6$ 元， $c_s = 0.15$ 元。

现使用改进的 Adam 算法求解该时段的最佳服务人员配置策略，使得目标函数最小化，异常变点时段单位时间内的成本优化过程如图 2-10 所示。




图 2-10 成本优化

优化后各节点服务人员配置情况及系统指标见表 2-11。

表 2-11 突发变点处优化后的系统指标

08:50-12:00	节点 1	节点 2	节点 3
$x_{1T_1'}$	26	12	35
μ_i	0.276	0.235	0.137
$\rho_{1T_1'}$	0.697	0.496	0.764
$EL_{1T_1'}$	0.133	0.021	0.292
总成本（美元、分钟）		1616.684	

分析图 2-10 与表 2-11 可知,当服务系统中客户到达率突然增加到 5 人/min 时,系统按照第一阶段的优化方案配置的各节点坐席人员数量,即节点 1、2、3 分别配 11、5、13 位坐席人员,已经无法满足现场需求。此时节点 1、2、3 分别需要 26、12、35 位坐席人员,才能使得单位时间的总成本达到最小。因此,在第一阶段优化方案的基础之上,节点 1、2、3 需要现场调配 15、7、22 位临时坐席人员,才能满足由于客户到达率突然增大所导致的服务系统额外的人员需求。对比优化前后各指标,按照第二阶段的人员配置策略进行优化后,3 个节点在异常变点处的服务强度均有所降低,系统内的平均等待人数明显减少,优化效果明显。在线优化的模拟结果表明,本文的优化模型能够及时调整服务人员的配置策略,有效应对现场突发情况,具有良好的适用性。

3 结论

以往关于排队系统的研究主要基于客户平稳到达的理论假设，未能充分考虑到客户到达的随机性。但受各种不确定因素影响，现实生活中的排队系统往往呈现出非平稳特征，特别是在呼叫中心领域，随着其普及化以及服务规模的扩大，传统的平稳排队模型已难以准确刻画系统的运行特征。基于此，本研究以呼叫中心为背景，构建了基于贝叶斯在线与离线变点监测的两阶段优化模型，用于解决客户非平稳到达环境下服务人员配置的优化问题。该模型采用两阶段优化策略，第一阶段基于客户到达的历史数据，引入贝叶斯离线变点监测方法对客户到达过程进行分段处理，并以客户与呼叫中心总成本最小化为目标，利用梯度下降优化算法得到全局最优服务人员配置策略。该阶段基于历史数据，为服务人员配置提供初步优化方案，并为后续的动态调整奠定了基础。第二阶段在第一阶段人员配置策略的基础上，根据客户到达的实时数据流，采用贝叶斯在线变点监测方法对客户到达率的变点进行实时监测，一旦监测到异常变点，立即采用梯度优化算法对该异常时段的人员配置进行在线调整，使得单位时间的总成本最小化。该阶段基于实时数据流，对异常变点时段的服务人员进行动态调整，实现服务人员配置策略的局部最优。

为验证模型与算法的有效性，本文以美国某银行呼叫中心的数据进行实例分析，选取其人工服务阶段某部分的服务流程进行研究，建立排队网络模型，并进行离线与在线两阶段的人员配置优化。结果表明，基于贝叶斯离线与在线变点监测的两阶段人员配置优化模型能够准确识别客户到达率的变点，降低客户等待成本与呼叫中心的运营成本，保障服务水平，模型与算法具有良好的适用性。

综上，本文构建的基于贝叶斯离线与在线变点监测的两阶段优化模型能够准确识别客户到达规律的变化，实现人员配置全局最优与局部最优之间的平衡，对呼叫中心等服务系统如何制定合适的服务人员配置策略具有一定的现实指导意义。