

车身智能自适应集成模型

姓名： 孙凯月

学号： B240200161

一、研究目的

考虑车辆在复杂载荷激励下的振动工况，针对车辆车身的主要结构如车架、车厢等开展多重目标的结构优化设计研究。针对车身结构优化过程中多重目标函数难以显性表达的问题，通过融合多个候选近似模型，研究车身结构自适应集成模型的构建方法，并实现对候选基学习器的自适应选择。

二、车身智能自适应集成模型

集成模型可以集成多个个体近似模型（以下称作“基学习器”）建立模型精度和泛化能力更高的统一模型，通过替代有限元模型可以大幅降低优化过程的计算成本，提升设计效率。然而，集成模型的构建过程仍然存在基学习器自适应选择问题。同时，采用集成模型实现车身结构轻量化设计的研究相对较少。为了实现对不同基学习器的自适应集成，车身智能自适应集成模型（IASM）的构建过程由基学习器编码及初始化、堆叠法模型训练、综合性能评价和基学习器智能优化四个阶段组成。其中，基学习器编码及初始化实现对不同基学习器的编码，并以编码组合作为一组种群，用于后续的优化迭代；堆叠法模型训练实现对不同基学习器的模型训练；综合性能评价实现对所构建集成模型的适应度值评估；基学习器智能优化完成 IASM 自适应构建。

2.1 基学习器编码及初始化方法

基学习器的数量和类别对集成模型性能的影响较大。在 IASM 模型构建过程中，对基学习器的选择只存在两种情况：保留和剔除。为了便于 IASM 的自适应集成，需要对不同基学习器进行合理的编码。本文采用二进制编码的方式对各个基学习器进行“0”和“1”的编码。如果基学习器的编码为“0”，则表示 IASM 对该基学习器执行“剔除”操作，在集成过程中不考虑集成该基学习器。反之，如果基学习器编码为“1”，则表示 IASM 对该基学习器执行“保留”操作，在集成过程中保留该基学习器。假设候选基学习器的数量为 n ，则编码可以用以下公式表达：

$$x_n = \{0,1\} \quad (1)$$

其中， x_n 表示第 n 个基学习器， $\{0,1\}$ 表示 0 和 1 的编码集合。为了实现 IASM 自适应集成，需要对基学习器的组合进行优化。IASM 采用染色体表

达方式对全部候选基学习器进行编码，每一条染色体代表一组基学习器组合，其表达式如下：

$$X_{BL} = \{x_1, x_2, x_3, \dots, x_n\} \quad (2)$$

其中， X_{BL} 表示一条基学习器染色体，包含各个基学习器的编码。在 IASM 构建过程中，需要对不同组合的 X_{BL} 进行评估，优化得到最佳的一组 X_{BL} 。因此，需要将 X_{BL} 视为优化过程中的一组种群。在优化开始前，需要对种群进行初始化，其表达式如下：

$$\begin{cases} X_{BL}^t = \{x_1^t, x_2^t, x_3^t, \dots, x_n^t\} \\ x_n^t = \text{rand}(0,1) \end{cases} \quad (3)$$

其中， X_{BL}^t 表示第 t 次优化迭代的染色体种群， x_n^t 表示第 t 次优化迭代中第 n 个基学习器的编码， $\text{rand}(0,1)$ 表示在 0 和 1 中随机生成任意数。基学习器编码及初始化的流程如图 1 所示。




图 1 基学习器编码及初始化

2.2 基于堆叠方法的模型训练

堆叠方法属于一种双层模型训练框架，第一层是各个基学习器的训练层，第二层是元学习器的训练层。在第一层训练过程中，首先对每个基学习器进行训练，通过测试集对每个基学习器进行测试并返回预测结果。接着，将每个基学习器返回的预测集进行整合，将这些预测集作为输入，对应的真实值作为输出，训练第二层的元学习器。通过两层训练，最终完成集成模型的构建。在堆叠方法的训练过程中有两个关键阶段会影响模型整体性能，即第一层训练过程采用的 k 折交叉验证方法和第二层训练过程选择的元学习器类型。 k 折交叉验证方法是一种模型训练过程中常用的验证方法。该方法能够充分利用有限的的数据，有助于更准确、更稳定地评估模型性能。图 2 展示了 k 折交叉验证的基本流程。如图所示， k 折交叉验证方法的运行过程包

括以下步骤：

- 步骤一：将原始数据集随机分割成 k 个互不重叠的子集，每个子集称为一个“折”；
- 步骤二：对个体基学习器进行 k 次独立数据训练，在每次训练过程，从 k 折数据中选择 1 折作为验证集，其余 $k-1$ 折作为训练集；
- 步骤三：在一组独立数据上训练并验证评估模型性能，产生一个模型误差；
- 步骤四：重复步骤二和步骤三，直到每一折都被用作过验证集；
- 步骤五：对基学习器所得到的 k 个验证误差求均值，得到模型的最终误差。




图 2 k 折交叉验证流程图

在堆叠方法训练模型过程中采用 k 折交叉验证方法的原因可以概括为：

- (1) 通过对原始数据集进行 k 次不同训练集和测试集的分割，能够降低模型性能估计的方差，使得模型性能的评估更加稳定和可信；
- (2) 降低集成模型过拟合可能性，可以确保第二层训练数据是在与其独立的数据上生成的，从而减少过拟合的风险；
- (3) 生成更稳健的第二层训练集，减少模型预测的噪音并提高集成模型的准确性；
- (4) 充分利用原始数据集，在数据量有限的情况下尤其重要。

第一层训练过程中集成了多个基学习器，并且采用基学习器的预测集作为元学习器的训练集。为进一步降低集成模型过拟合风险，第二层元学习器通常采用线性回归模型 (Linear Regression Model, LRM)，原因在于 LRM 的结构简单，不容易出现过拟合现象。同时，相比于一些更复杂的模型，LRM 的计算效率更高，这在处理大规模数据的情况下尤为重要。在 LRM

中，假定输入与输出之间具有线性相关的关系，给定由 d 个特征构成的输入向量 $X = (x_1, x_2, \dots, x_d)$ ，其中 x_i 是 X 第 i 个特征上的取值，线性回归模型将构建一个通过特征的线性组合来进行预测的函数：

$$f(X) = \theta^T X + b \quad (4)$$

其中， θ 为特征系数， b 为偏置。为了使 $f(X)$ 中保留常数项，通常 $x_0 = 1$ ，所以输入向量 $X = (x_1, x_2, \dots, x_d)$ 。假设通过线性回归模型所预测的结果与真值之间存在误差，则构建损失函数表达式为：

$$J(\theta) = \frac{1}{2} \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2 \quad (5)$$

其中， $J(\theta)$ 表示关于特征系数向量的损失函数， y_i 表示数据集真值， $f_{\theta}(x_i)$ 表示预测值。通常采用最小二乘方法来求解线性回归模型的参数，可以将上式转化为矩阵形式：

$$J(\theta) = \frac{1}{2} (X\theta - y)^T (X\theta - y) \quad (6)$$

其中， X 为输入向量， θ 为特征系数向量， y 为数据集真值矩阵。因最小二乘方法将问题转化为凸优化问题，则对上式中的向量 θ 求导，并令导数为零可以得到：

$$\theta = (X^T X)^{-1} X^T y \quad (7)$$

通过上述流程，可以利用训练集求得线性回归模型的特征系数，完成集成模型训练。图 3 为堆叠方法构建集成模型的流程示意图。图中 $x_1, x_2, \dots, x_n$ 代表各个基学习器，通过第一层训练及测试，生成对应的预测集。进入堆叠第二层，将各个预测集作为输入，数据真值作为输出对元学习器进行训练，获得集成模型。线性回归模型的运行流程如下：

步骤一： 模型参数初始化；

步骤二： 使用训练数据训 LRM 模型，获得特征系数，完成模型构建；

步骤三： 使用测试数据评估训练后的线性回归模型的性能；

步骤四： 重复第二步至第三步，通过调整模型参数来提高模型性能。




图 3 堆叠方法构建集成模型流程

2.3 模型综合性能评估指标

评估指标能够解释集成模型的预测性能，不同的评估指标从不同方面来评估一个模型的预测能力。常用的模型评估指标包括均方根误差、平均绝对误差和决策系数。均方根误差（Root Mean Square Error, RMSE）是近似模型最常用的评价指标。该指标遵循一个假设，即误差是无偏的并遵循正态分布。RMSE 表示预测值和真值之间残差的样本标准差，能够体现预测结果中的异常值情况。该指标说明了样本的离散程度并且取值越小越好。RMSE 的计算表达式如下：

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (8)$$

其中， y_i 表示样本集的真值， $\hat{y}_i$ 表示通过集成模型的预测值， m 代表样本个数。平均绝对误差（Mean Absolute Error, MAE）是衡量预测值和真值之间绝对误差的平均值。MAE 属于一种线性评价指标，即个体差异在平均值上的权重都相等。相较于 RMSE 来说，MAE 体现模型整体的误差水平，其表达式如下：

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i| \quad (9)$$

其中， y_i 表示样本集的真值， $\hat{y}_i$ 表示通过集成模型的预测值， m 代表样本个数。尽管 RMSE 和 MAE 可以反应模型的准确度和稳定性，但仅凭这两个指标不能直观反应模型拟合情况。因此，还需要采用决策系数（R-Squared, R^2 ）这一指标来衡量模型拟合性能。 R^2 是模型的预测值与真值之间相关系

数的平方，其取值范围为 0 到 1，取值越大表示预测值与真值越接近，模型的拟合精度越高。 R^2 表达式如下：

$$R^2 = 1 - \frac{\sum (\hat{y}_i - y_i)^2}{\sum (\bar{y} - \hat{y}_i)^2} \quad (10)$$

其中， y_i 表示样本集的真值， $\hat{y}_i$ 表示通过集成模型的预测值， $\bar{y}$ 表示样本平均真值。RMSE、MAE 和 R^2 三个指标分别从不同角度来评价模型的性能。然而，IASM 模型的构建目标是在所有可能的基学习器组合中找到最好的一个组合来构建集成模型，所以有必要构建一个综合性评价指标。为了更加直观和便捷地对模型进行综合评估，利用一种综合评价指标（Comprehensive Evaluation Index, CEI）来评估模型性能，其表达式为：

$$CEI = \frac{1}{(R^2)^\alpha} \cdot RMSE^\beta \cdot MAE^\gamma \cdot \mu \quad (11)$$

其中， $\alpha, \beta, \gamma, \mu$ 该指标的控制系数。CEI 指标可以综合地评估集成模型性能，其值越小，表示模型的误差、异常值及拟合精度表现越好，即模型综合性能越好。通过测试，参数设置为 $\alpha=2, \beta=1, \gamma=0.1, \mu=10000$ 。将样本真值、样本均值及预测值表达式代入该公式，CEI 指标的表达式可进一步表示为：

$$CEI = \frac{10000(\sum (\bar{y}_i - \hat{y}_i)^2)^2 \cdot \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \cdot (\frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|)^{0.1}}{(\sum (\bar{y}_i - \hat{y}_i)^2 - \sum (\hat{y}_i - y_i)^2)^2} \quad (12)$$

其中， y_i 表示样本集的真值， $\hat{y}_i$ 表示通过集成模型的预测值， $\bar{y}_i$ 表示样本平均真值， m 代表样本个数。

2.4 基学习器智能优化及 IASM 实现

为了实现 IASM 的自适应构建，需要对各个基学习器组合进行优化求解。基于该编码规则，采用三种遗传算子来对各染色体的编码进行优化，即通过选择算子、交叉算子和变异算子来逐步更新基学习器染色体 X_{BL} 。这些遗传算子能够使 IASM 在构建过程中通过更新染色体寻找到最佳基学习器组合。

在选择算子的运行过程中，采用轮盘赌选择（Roulette Wheel Selection, RWS）来完成对迭代过程中染色体的选择。RWS 是在进化算法中用于选择染色体进行后续优化迭代的一种常见方法。这种方法的基本思想是给每个

染色体赋予一个选择概率，这个概率与其适应度评估情况成正比，即适应度评估越好的染色体被选中的概率越高。假设有 N 个染色体，则第 i 个染色体被选择概率表达式为：

$$p_s = \frac{f_i}{\sum_{i=1}^N f_i} \quad (13)$$

其中， p_s 表示染色体被选中的概率， f_i 表示第 i 个染色体对应的适应度值， $\sum_{i=1}^N f_i$ 表示全部染色体适应度值的总和。上式可以看出，适应度值越好的染色体其选择率越高。图 4 展示了 RWS 方法的运行示意图。




图 4 RWS 运行示意图

尽管 RWS 可以在全部染色体种群中选择适应度较好的染色体，进行后续的优化迭代，仅仅通过 RWS 算子容易造成优化陷入局部极小值情况。因此，需要采用其他算子来增加染色体种群的多样性，交叉算子和变异算子能够实现此功能。交叉算子是通过设定的交叉概率来对染色体内不同基因进行交换操作，生成新的染色体，其运行流程如图 5 所示。染色体 A 和染色体 B 上对应位置的基因将依据交叉概率进行交换生成新的染色体，进入后续优化迭代中。通常，交叉概率越大，则新生代染色体群体的多样性越大，全局寻优能力越强，但可能导致不收敛情况出现。相反，如果交叉概率较小，则优化容易陷入局部最小。一般交叉概率选取 $p_c = 0.7$ 时优化效果较理想。

与交叉算子相比，变异算子是通过变异概率 p_m 对单个染色体上的基因进行逐一变异，生成新的染色体并进入后续优化迭代中。图 6 展示了变异算子运行示意图。染色体 A 上的每一个基因都要依据变异概率进行相应的变异操作，而后生成的新染色体进入后续优化迭代。由于变异存在的不确定性和无序性，通常是以较小的变异概率进行变异操作。如果变异概率过高，

可能会使优异的染色体基因丢失而降低整体寻优效果，通常变异概率设为 $p_m=0.05$ 。




图 5 交叉算子运行示意图




图 6 变异算子运行示意图

通过上述方法，IASM 能够对基学习器组合不断优化迭代，每次迭代都会返回具有最佳适应度值的染色体。随着整个迭代过程的结束，最佳染色体将被确定，即集成了最佳基学习器组合的集成模型 IASM 构建完成。如图 7 所示，每个基学习器被组合并编码为二进制序列的染色体，初始化得到数量为 N 的染色体种群，这些种群将进入后续的优化过程，在经过优化迭代后生成性能最优的 IASM 模型。图中以一条染色体为例，IASM 的构建流程：

步骤一：对基学习器进行编码，构建基学习器染色体并生成初始化种群；

步骤二：生成的染色体种群进入堆叠方法训练层，采用常用的 5 折交叉验证方法，训练每个编码为“1”的基学习器，对编码为“0”的基学习器不做任何训练；

步骤三：第一层训练完毕，将各个编码为“1”基学习器的预测结果进行整合，输入到第二层训练层，对元学习器进行训练；

步骤四：经过两层训练后，评估各个染色体的适应度函数值，然后进行染色体更新操作。通过 RWS 方法选择染色体，通过交叉和变异算子生成新染色

体，进行下一次堆叠模型训练阶段；

步骤五：重复步骤二至步骤四，直到优化终止。




图 7 自适应 Stacking 模型流程图

IASM 模型构建的表达式如下：

$$\begin{aligned} \min \quad & \varepsilon_{IASM} = CEI\{\hat{y}(X_{BL}), y, \bar{y}\} \\ s.t. \quad & x_i^t = \{0, 1\}, i = 1, 2, 3, \dots, n \end{aligned} \quad (14)$$

其中， X_{BL} 表示第 t 次优化迭代中的染色体， ε_{IASM} 表示所构建 IASM 的全局性能指标，CEI 表示由 X_{BL} 所构建集成模型的综合性能评估值， $\hat{y}(X_{BL})$ 表示由 X_{BL} 所构建集成模型的预测值， y 表示样本集的真值， $\bar{y}$ 表示样本平均真值， x_i^t 表示第 t 次优化迭代中第 i 个基学习器的编码。

2.5 工程实例测试实验及结果分析

利用两个车辆结构实例来测试原始堆叠集成模型（OSM）和 IASM 的性能，验证 IASM 处理工程问题的有效性。这些工程实例具有不同的样本数据、特征数据和响应值，能够验证待测试模型在处理不同样本规模工程问题的模型性能。

1) 车架综合性能预测

车架作为车辆主要承重结构，其轻量化设计不仅能够提升其抗变形能力，而且对节能减排具有重要意义。为验证车架 IASM 性能，首先采用 SFE-CONCEPT 软件构建了车架的几何参数模型，其整体长宽分别是 7063.5mm

和 852mm。所建立的车架零部件材料均设置为钢。通过 Hypermesh 软件对车架模型进行有限元网格划分，最终生成的有限元模型含有 3596366 个单元和 1165034 个节点。车架的几何模型如图 8 所示。




图 8 车架几何模型图




图 9 车架关键变量示意图

为了构建车架集成模型，需要确定车架的设计变量和性能响应。依据某企业设计开发规范，选取了10个影响车架整体性能的关键变量，如图 9 所示。图中各关键变量的描述、初始尺寸及变量范围详见表 1 所示。为充分验证 IASM 模型的性能，选取了影响车架轻量化的七个性能指标，包括质量、弯曲刚度、前扭转刚度、后扭转刚度、一阶扭转模态、一阶横向弯曲模态和一阶纵向弯曲模态。各性能的代表符号见表 2 所示。

采用最优拉丁超立方采样进行了实验设计，通过 CAE 仿真获得了 400 组数据，用于训练 OSM 和 IASM 模型，模型参数设置与前文一致，性能结果见表 3。分析各个性能指标可以看到，IASM 在车架弯曲刚度、后扭转刚

度、一阶扭转模态各指标上的性能优越,其 R^2 均超过了 0.99, RMSE 和 MAE 均小于 0.15。OSM 表现的性能逊于 IASM, 其 R^2 值分别为 0.978、0.982 和 0.981, RMSE 和 MAE 均超过了 0.18。在前扭转刚度、一阶横向弯曲模态、一阶纵向弯曲模态和车架质量这四个响应的预测性能上, IASM 各项性能指标均好于 OSM。通过综合性能指标 CEI 可以看出, IASM 在车架七项响应上的预测性能明显好于 OSM, 其中, 在车架质量和前扭转刚度上的性能优势更明显。总的来说, IASM 在车架综合性能上的预测性能明显好于 OSM, 且模型精度均超过了 0.975, 误差均小于 0.17, 能够满足工程设计的需求。

表 1 车架关键变量信息

符号	变量描述	初始值 (mm)	变量范围 (mm)
x ₁	平衡悬架横梁 x 向尺寸	210	[-30,30]
x ₂	中桥处横梁 x 向尺寸	115	[-20,30]
x ₃	纵梁 y 向尺寸	75	[-30,30]
x ₄	后横梁 x 向尺寸	130	[-30,30]
x ₅	中央横梁 x 向尺寸	210	[-30,30]
x ₆	一轴板簧固定端管径	42.5	[-4.5,7.5]
x ₇	中桥横梁厚度	5	[-2,1]
x ₈	中桥横梁连接板厚度	6	[-2,2]
x ₉	中央横梁厚度	4	[-1,2]
x ₁₀	中央横梁连接板厚度	6	[-2,2]

表 2 车架待测试性能


名称	表示符号
弯曲刚度	K_{cBD}
前扭转刚度	K_{cFTR}
后扭转刚度	K_{cRTR}
一阶扭转模态	M_{cTR}
一阶横向弯曲模态	M_{cLB}
一阶纵向弯曲模态	M_{cVB}
车架质量	M_c

为了更加直观对比分析 IASM 和 OSM 模型性能, 图 10 展示了车架前扭转刚度、弯曲刚度、一阶扭转模态和质量的模型散点图。从图 10 (a) 和 (c) 中可以看出, OSM 模型的预测点在目标线附近, 但不够集中, 而 IASM 模型预测点集中在目标线周围, 性能好于 OSM。从图 10 (b) 和 (d) 中可以看出, IASM 的预测点位置明显好于 OSM。可见, 对于车架各性能的预


测能力，IASM 比 OSM 展现出了更好的模型精度和鲁棒性。

表 3 车架预测性能对比


性能指标	模型	K_{cBD}	K_{cFTR}	K_{cTR}	M_{cTR}	M_{cLB}	M_{cVB}	M_c
RMSE	OSM	0.022	0.036	0.022	0.021	0.016	0.019	0.043
	IASM	0.007	0.017	0.014	0.014	0.006	0.011	0.012
MAE	OSM	0.018	0.027	0.018	0.018	0.012	0.015	0.033
	IASM	0.005	0.013	0.011	0.011	0.005	0.009	0.010
R ²	OSM	0.978	0.963	0.982	0.981	0.969	0.975	0.954
	IASM	0.996	0.984	0.996	0.992	0.975	0.989	0.989
CEI	OSM	153.91	270.51	152.66	146.02	109.49	131.33	335.91
	IASM	41.54	113.72	89.90	90.62	37.16	70.21	77.41




(a) 弯曲刚度预测性能对比



(b) 前扭刚度预测性能对比



(c) 一阶扭转模态预测性能对比



(d) 质量预测性能对比

图 10 车架 IASM 模型性能对比

2) 车厢综合性能预测

车厢结构安全性对于驾驶安全性和舒适性起到至关重要的最用。车厢属于复杂的车身结构，由侧板、车顶板、地板、前面板和后面板等众多部件构成。图 11 展示了车厢几何参数模型，其整体长宽高分别是 2490mm、1760mm 和 1790mm。通过有限元网格划分，生成了 524271 个网格单元和 529405 个节点。为了构建车厢集成模型，需要确定其设计变量和性能响应。统一参考某企业设计开发规范，选取了 15 个影响车厢整体性能的关键变量，如图 11 所示。各关键变量的描述、初始尺寸及变量范围详见表 4 所示。选取了影响车厢轻量化的四个关键性能指标，包括扭转刚度、弯曲刚度、一阶扭转模态和车厢质量，见表 5 所示。






图 11 自适应 Stacking 模型流程图


通过 CAE 仿真获得了 400 组数据，用于训练 OSM 和 IASM 模型，模型性能结果见表 6。可以看到，OSM 在扭转刚度和一阶扭转模态上的性能较理想，其 RMSE、MAE 和 R^2 值略差于 IASM。对于弯曲刚度和车厢质量来说，IASM 的表现明显好于 OSM。通过综合性能指标 CEI 可以看出，IASM 在四个响应上的综合性能均好于 OSM。IASM 在车厢综合性能上的预测性能优异，其模型精度均超过了 0.974，误差均小于 0.36，满足需求。




(a) 扭转刚度预测性能对比



(b) 弯曲刚度预测性能对比



(c) 一阶扭转模态预测性能对比



(d) 质量预测性能对比

图 12 车厢 IASM 模型性能对比

图 12 展示了 OSM 和 IASM 在四个车厢性能响应上的模型散点图。从图 12 (a) 中可以看出, 尽管 OSM 和 IASM 在扭转刚度上的表现相近, 都没有集中在目标线上, IASM 的表现仍好于 OSM。从图 12 (b) 可以看到, IASM 的预测点更加集中, 围绕在目标线附近, 而 OSM 的预测点过于分散。对于一节扭转模态, 图 12 (c) 展现了 OSM 和 IASM 均展现了较为理想的预测性能。进一步对比可以发现, OSM 预测点偏离目标线的程度大于 IASM。从图 12 (d) 上可以看出 IASM 的表现明显好于 OSM 模型的预测点在目标线附近, 但不够集中, 而 IASM 模型预测点集中在目标线周围, 性能好于 OSM。从图 12(b)和(d)中可以看出, IASM 的预测点位置明显好于 OSM。总的来说, 针对车厢各性能, IASM 展现出了更好的模型精度和鲁棒性。

表 4 车厢关键变量信息			
符号	变量描述	初始值 (mm)	变量范围 (mm)
x ₁	上 A 柱 X 向尺寸	170	[-20,20]
x ₂	前门框上边梁 Z 向尺寸	140	[-10,10]
x ₃	B 柱 X 向尺寸	300	[-20,20]
x ₄	前门框下端 Z 向尺寸	85	[-15,15]
x ₅	后门框上边梁 Z 向尺寸	135	[-15,15]
x ₆	C 柱前端 X 向尺寸	240	[-20,20]
x ₇	后门框下端 Z 向尺寸	135	[-15,15]
x ₈	后地板前横梁 X 向尺寸	95	[-15,15]
x ₉	后地板前横梁 Z 向尺寸	50	[-10,10]
x ₁₀	后地板中纵梁 Y 向尺寸	65	[-15,15]
x ₁₁	后地板中纵梁 Z 向尺寸	48	[-10,10]
x ₁₂	后地板后横梁 X 向尺寸	115	[-10,10]
x ₁₃	后地板后横梁 Z 向尺寸	80	[-10,10]
x ₁₄	后背板横梁 X 向尺寸	15	[-10,15]
x ₁₅	后背板横梁 Z 向尺寸	85	[-15,15]

表 5 车厢待测试性能	
名称	表示符号
扭转刚度	K_{xTR}
弯曲刚度	K_{xBD}
一阶扭转模态	M_{xTR}
车厢质量	M_c

表 6 车架预测性能对比					
性能指标	模型	K_{xTR}	K_{xBD}	M_{xTR}	M_c
RMSE	OSM	0.044	0.039	0.012	0.049
	IASM	0.036	0.022	0.010	0.009
MAE	OSM	0.039	0.031	0.009	0.038
	IASM	0.028	0.017	0.008	0.007
R ²	OSM	0.967	0.964	0.991	0.897
	IASM	0.974	0.987	0.996	0.996
CEI	OSM	340.18	296.52	76.29	439.13
	IASM	265.40	150.26	62.20	55.24

三、小结

针对车身结构优化过程中存在的难以显性表达的优化问题，提出一种车身结构自适应集成模型的构建方法，该方法采用集成的思想融合多个候选近似模型，能够有效利用各个候选模型的优势，提升整个模型的准确性和鲁棒性。自适应集成模型采用遗传算子，对各个候选模型进行编码、选择、

交叉和变异，优化模型结构，完成集成模型的构建。所提出集成模型实现了对候选基学习器的自适应选择，能够在处理不同类型问题时获得更好的模型精度和泛化能力。