

基于PSO算法优化LSTM的PM2.5浓度预测模型

黄涛

(湖南大学)

摘要：针对传统长短期记忆网络（LSTM）在超参数选择上依赖经验、易陷入局部最优解且收敛效率较低的问题，本文提出一种基于粒子群优化（PSO）算法优化的LSTM模型用于PM2.5浓度预测。利用PSO算法优化LSTM的网络结构参数，有效规避局部最优陷阱，提升模型训练效率。实验选取北京市附近10个地区的气象数据，。结果表明，PSO-LSTM模型在测试集上的决定系数达0.981，平均绝对误差为4.21，均方根误差为6.54。此外，PSO算法显著加快了模型收敛速度，减少了训练耗时。该模型通过智能优化超参数，解决了传统LSTM的局限性，为PM2.5浓度精准预测提供了高效解决方案，可为城市空气质量预报与污染防控提供技术支撑。

关键词：PM2.5 浓度；预测模型；PSO 算法；LSTM

PM2.5 Concentration Prediction Model Optimized by PSO Algorithm Based on LSTM

Huang Tao

(Hunan University)

Abstract: To address the issues of traditional Long Short-Term Memory (LSTM) networks, such as reliance on empirical parameter selection, susceptibility to local optima, and low convergence efficiency, this paper proposes an LSTM model optimized by Particle Swarm Optimization (PSO) for PM2.5 concentration prediction. By using the PSO algorithm to optimize the network structure parameters of LSTM, it effectively avoids the local optimum trap and enhances the training efficiency of the model. The experiment selected meteorological data from 10 regions near Beijing. The results show that the PSO-LSTM model achieves a determination coefficient of 0.981 on the test set, with an average absolute error of 4.21 and a root mean square error of 6.54. Additionally, the PSO algorithm significantly accelerates the model's convergence speed and reduces training time. This model, through intelligent optimization of hyperparameters, overcomes the limitations of traditional LSTM, providing an efficient solution for accurate PM2.5 concentration prediction and offering technical support for urban air quality forecasting and pollution control.

Keywords: PM2.5 concentration; prediction model; PSO algorithm; LSTM

0. 引言

PM2.5，即细颗粒物，其尺寸微小且具有强烈的吸附能力，它们在大气中停留时间长，能远距离传输，并可通过呼吸深入人体肺部和血液。这些颗粒物含有的重金属等有毒物质，会对呼吸系统、免疫系统和循环系统造成破坏，引发呼吸道疾病、心血管疾病，乃至肺癌等严重健康问题。随着工业化和城市化进程的加快，空气污染问题日益严重，PM2.5作为主要污染物之一，其直径越小，对人体和环境的危害越大。特别是在人口密集和经济发达地区，PM2.5对人体健康的影响尤为显著。因此，建立一个能够准确预测PM2.5浓度的模型，对于大气污染防治和实现可持续发展至关重要。随着经济的增长，环境污染问题也日益凸显。汽车尾气、工业排放和取暖排放等活动导致空气中PM2.5浓度增加，进而引发肺部疾病和心脑血管疾病，对人类健康构成威胁。精准的PM2.5浓度预测对于提前采取防护措施、保护人类健康具有重要意义。本研究旨在通过粒子群优化（PSO）算法优化的BP神经网络，提高PM2.5浓度

预测的准确性，为环境管理提供科学依据，以减轻PM2.5对公共健康的影响

在环境科学和人工智能交叉的研究领域中，PM2.5浓度预测对空气质量和人类健康有着显著影响，因此受到了众多学者的广泛关注。张丹宁等提出了基于BP神经网络的PM2.5浓度预测模型，该模型利用西安市的大气污染物监测数据进行训练学习，并用后续数据进行测试和检验，建立了精度较高的PM2.5浓度预测模型，有效预测次日PM2.5浓度值，并针对偏差较大的预测结果进行了成因分析和讨论。邸鹏等则基于BP神经网络建立了北京市PM2.5浓度预测模型，通过高精度拟合的BP网络预测模型，反映了北京市雾霾天气状况，为空气质量监测和预报提供了参考。彭豪杰等综合考虑深度学习与随机森林的特点，提出了基于深度学习与随机森林的PM2.5浓度预测组合模型，该模型在较少数据情况下具有较好的预测精度，尤

其是在使用LSTM作为特征选择器、RF为回归器的组合模型中表现最优。张旭等提出了改进的PSO-GA混合算法对BP神经网络的初始权值和阈值进行设定，有效避免了陷入局部极小，提高了收敛速度，仿真结果表明改进的模型比PSO-BP预测模型收敛性更好。胡俊等建立了基于改进人工蜂群BP神经网络的PM2.5质量浓度预测模型，通过优化人工蜂群算法的寻优精度与收敛速率，提升了模型的稳定性和预测精准性。

这些研究表明，尽管已有多种方法被提出以提高PM2.5浓度预测的准确性，但仍需进一步优化算法以增强模型的泛化能力和适应性，特别是在数据量较少或数据存在缺失时的预测性能。本研究旨在通过改进PSO算法优化BP神经网络，提高PM2.5浓度预测的准确性和鲁棒性，从而为大气污染防治提供更为可靠的决策支持。

1. 数据来源和分析

1.1 数据来源

本研究选取北京附近地区作为研究对象，如图1所示，数据来源为KnowAir-V2：用于空气污染预测的PCDCNet基准数据集（<http://meicmodel.org.cn>），该数据库涵盖了2016年1月至2023年12月期间的逐时大气污染物监测数据。研究涉及的污染物包括PM2.5（细颗粒物）、O3（臭氧）、t2m（两米空气温度）、d2m（2米露点温度）、tp（总降水量）、sp（表面压力）、blh（边界层高度）、msdswrf（平均向下短波辐射通量）、u100（100米高度风速分量）和v100（100米高度风速分量）等关键指标，旨在通过这些数据预测北京附近的PM2.5浓度值，为居民出行和健康防护提供科学依据。原始实验数据如表1所示。




图1 北京附近地图

表1 原始数据库数据

检测时间	PM2.5	O3	...	U100
2016-1-1	277	11	...	0.666
2016-1-2	305	13	...	0.8698
...	...	...	...	...
2016-6-30	73	197	...	3.693

1.2 数据选择及处理

本文选择数据库中前十个站点的监测数据作为整体的数据集，地点从北京的万寿西宫到昌平镇，因为冬季的PM2.5污染比较严重，所以选择11月到第二年的2月整个冬季的数据。为每个冬季时段生成每隔4小时的时间点（因为原始数据可能是每小时或更频繁的，这里降采样到4小时）。对于每个变量（如O3、u100、v100等），提取指定站点在4小时间隔时间点的值。添加时间相关的特征，如小时、星期几、月份、一年中的第几天。这些特征有助于模型捕捉季节性和周期性模式。创建PM2.5的滞后特征（前1、2、3个时刻的值），即用过去3个时间点（12小时）的PM2.5值作为特征，捕捉时间依赖性。计算过去12小时（3个4小时）和24小时（6个4小时）的PM2.5移动平均值，平滑短期波动，捕捉趋势。

将数据按时间顺序分割为训练集（80%）和测试集（20%）。：这里没有随机分割，而是按时间顺序分割，因为时间序列数据需要保持时间顺序。再将训练集分割为最终训练集（80%的训练集）和验证集（20%的训练集）。这样，整个数据集被分为：训练集（64%）、验证集（16%）、测试集（20%）。

1.3 数据归一化处理

为了使模型对数据识别，需要对数据特征化处理，将文本类型的数据转换成数值类型的数据，对数据进行特征化处理以后，所有的数据都变成了数值类型的数据，但是数据的维度不同，单位不同，会降低模型预测结果的准确率，需要对数据进行归一化处理，本文使用的是Z-score的归一化方法。score 使用原始数据的平均值和标准差来实现归一化，处理以后的数据均值为0，标准差为1，符合正态分布。具体公式如下：

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

其中，x是原始数据，μ是均值，σ是标准差，z是标准化后的数据。通过标准化，不同特征的数据将被调整到相同的尺度上，有助于提高模型的性能和收敛速度。数据归一化是数据预处理的一个重要环节，其目的是将不同尺度和量纲的数据转换到同一尺度，以便进行有效的比较和分析。

2. 研究方法

2.1 模型计算法原理

1997年，Hochreiter等推出了长短期记忆网络（LSTM），这是一种对RNN的改进，加入了“门（gate）”机制，使RNN中出现的梯度消失和梯度爆炸问题得到了有效的

解决。LSTM模型由遗忘门、输入门、输出门和单元状态四个部分构成（见图2）。




图2 LSTM结构图

遗忘门 f_t 负责确定 $t-1$ 时刻的信息有多少能够保留到 t 时刻，输入门 i_t 负责确定有多少新输入信息会被保留到当前单元状态 C_t 中，输出门 o_t 负责确定 C_t 中有多少信息会输出到LSTM模型的最终输出 h_t 中。其具体的计算公式为：

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \\ i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), \\ C'_t &= \tanh(W_c[h_{t-1}, x_t] + b_c), \\ C_t &= f_t C_{t-1} + i_t C'_t, \\ o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \\ h_t &= o_t \cdot \tanh(C_t), \end{aligned} \quad (2)$$

式中 f_t 为遗忘门状态； i_t 为输入门状态； C_t' 为前一时刻的细胞状态； C_t 为当前时刻的单元状态； o_t 为输出门状态； h_t 为 t 时刻的输出状态； x_t 为 t 时刻的输入状态； σ 为Sigmoid函数； $\tanh$ 为双曲正切激活函数； b_f, b_i, b_c, b_o 分别为遗忘门、输入门、细胞状态，输出门的偏置值； W_f, W_i, W_c, W_o 分别为遗忘门、输入门、细胞状态、输出门的权重矩阵；运算“ $\cdot$ ”为逐点乘法运算，两个相同维度的矩阵或向量的逐点乘法运算结果为对应位置上的元素相乘所得到的新的矩阵或向量。

粒子群优化（particleswarmoptimization, PSO）算法是一种模拟鸟群社会行为的群体智能技术，用于解决复杂的优化问题。该算法通过模拟鸟群捕食行为，让群体中的粒子在搜索空间中通过个体和群体经验协同搜索最优解。每个粒子根据自身经验和群体经验动态调整位置和速度，以探索潜在的解空间。假设有一个 d 维的目标搜索空间当中共有 m 个粒子，其中第 i 个粒子的位置和速度都是 d 维的空间向量 $x_i=(x_{i1}, x_{i2}, \dots, x_{id})$ 和 $v_i=(v_{i1}, v_{i2}, \dots, v_{id})$ ，其中 $i=1, 2, \dots, m$ 。每一次迭代后，速度和位置更新分别为：

$$v_{id}^{k+1} = wv_{id}^k + c_1r_1(p_{id}^k - x_{id}^k) + c_2r_2(p_{gd}^k - x_{id}^k) \quad (3)$$

$$x_{id}^{k+1} = x_{id}^k + v_{id}^{k+1} \quad (4)$$

其中， $p_i=(p_{i1}, p_{i2}, \dots, p_{id})$ 为第 i 个粒子目前搜索到的最优位置， $p_g=(p_{g1}, p_{g2}, \dots, p_{gd})$ 为目前整个粒子群搜索到的最优位置。和为第 i 个粒子在第 k 次迭代飞行和第 i 维的位置和速度分量， c_1, c_2 为粒子的学习因子， r_1, r_2 为 $[0, 1]$ 之间随机数， w 为惯性权重。这些更新

规则确保粒子在保持多样性的同时，能够有效地向最优解靠近。通过迭代更新，PSO算法能够平衡全局搜索和局部搜索的能力，从而在多维空间中找到问题的最优或近似最优解。在本研究中，PSO算法被用于优化BP神经网络的参数，以提高PM2.5浓度预测的准确性和效率。

2.2 模型构建

PM2.5浓度预测模型的构建如图3所示。为了加快学习算法的收敛速度，将数据进行归一化处理，并将数据划分为训练集和测试集。在模型构建中，首先确定BP神经网络的层数及每层所需的神经元个数。为了提高收敛速度和精度，采用PSO算法优化BP神经网络的初始权重和阈值，具体优化流程如图2所示。然后，使用训练集构建PM2.5的预测模型，最后使用测试集来预测次日的PM2.5浓度。




图3 PM2.5预测模型构建




图4 PSO算法优化LSTM流程图

（1）数据准备与预处理数据读取：时间序列处理：定义两个冬季时段提取每4小时间隔的数据，添加时间特征（小时、星期几、月份、年中日）创建滞后特征（前3个时刻的PM2.5值），创建移动平均特征（12小时和24小时平均）处理缺失值。

（2）数据分割与标准化，定义18个特征变量（气象要素+时间特征+滞后特征）按时间顺序分割为训练集(80%)和测试集(20%)训练集进一步分割为训练子集(80%)和验证集(20%)，使用StandardScaler进行特征缩放数据重塑。

（3）超参数优化（PSO）模型构造函数，根据超参数创建LSTM模型适应度函数，评估粒子（超参数组合）的性能PSO配置，优化5个超参数：LSTM单元数、Dropout率、学习率、批大小设置参数搜索范围和PSO参数（认知/社会参数、惯性权重）优化执行，运行PSO算法寻找最优超参数组合。

（4）模型训练与评估最终模型训练，使用PSO找到的最优参数构建模型训练过程中应用早停策略（EarlyStopping）多维度评估

：计算训练集、验证集和测试集的MSE、RMSE、MAE和R² 指标输出

2.3 评价指标

在本研究中，我们采用均方根误差（RMSE）、决定系数（R²）和平均绝对误差（MAE）作为评价BP神经网络模型预测PM2.5浓度精度的指标。具体计算式如式（5）至式（7）所示。均方根误差（RMSE）衡量预测值与实际值偏差的平方和的平均数的平方根，公式为：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$
 (5)

决定系数（R²）反映模型对数据的拟合程度，公式为：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$
 (6)

平均绝对误差（MAE）衡量预测值与实际值绝对偏差的平均值，公式为：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$
 (7)

其中，y_i 为实际观测值， $\hat{y}_i$ 为预测值， $\bar{y}$ 为实际观测值的平均值。这些指标综合评估模型的预测性能，RMSE和MAE越低表示预测误差越小，R²越接近1表示

3. 实验结果及分析

根据表2所示的实验结果，将经过预处理的数据输入到PSO优化的LSTM模型中，经过10次实验，模型在测试集上展现了较高的预测精度。具体而言，测试集的R²值达到0.969，表明模型解释了96.9%的方差，显示出较强的解释能力。同时，测试集的平均绝对误差（MAE）为5.929，均方根误差（RMSE）为6.364，这些指标均表明模型具有较高的预测精度和较低的误差水平。结果表明，该模型在PM2.5浓度预测任务中具有良好的拟合度和稳定性，为环境监测提供了一个有效的工具。

表2 指标统计结果

站 点 ID	R ²		MAE		RMSE	
	训 练 集	测 试 集	训 练 集	测 试 集	训 练 集	测 试 集
1001A	0.9931	0.9779	6.6525	5.7712	9.7162	7.6058
1002A	0.9890	0.979	5.7636	4.853	8.4929	6.3162
1003A	0.9937	0.9415	6.3441	7.5471	9.0291	12.8396
1004A	0.9937	0.9415	6.3441	7.5471	9.0291	12.8396
1005A	0.9921	0.982	6.4053	4.9991	9.9482	6.746
1006A	0.9946	0.9759	5.4663	5.5371	8.087	7.6528

1007A	0.9881	0.9623	7.4082	6.296	11.2818	9.7181
1007A	0.9935	0.9733	5.5852	6.318	8.3093	8.4971
1008A	0.9892	0.9754	4.9835	5.2291	8.7883	7.2989
1009A	0.9892	0.9754	4.9835	5.2291	8.7883	7.2989

为了验证模型的拟合度，实验分别在训练集、验证集、测试集以及整体数据集上进行仿真。从图3可以看出，模型在训练集（R=0.9906）、验证集（R=0.9524）以及测试集（R=0.9678）上均展现出了较高的相关系数（R值），这表明模型具有很好的拟合能力。图中的拟合线（FT）与理想线（Y=T）非常接近，进一步证实了模型预测值与实际值之间的高度一致性。此外，输出方程中的常数项（0.017至0.014）表明模型在不同数据集上的预测偏差较小，这有助于提高模型的泛化能力。由此可见，PSO优化的LSTM模型在本研究中表现出了优异的预测精度和稳定性。




图3 模型回归拟合度

图4展示了模型在迭代过程中的适应度变化情况。可以观察到，适应度值在初始几次迭代中迅速下降，并在随后的迭代中保持稳定。这表明PSO算法能够快速找到较优的参数配置，并在较少的迭代次数内实现收敛。该结果验证了PSO优化策略在提升LSTM模型预测精度方面的有效性。




图4 粒子群优化模型迭代误差变化曲线

图5展示了测试集中预测值与真实值的对比，其中蓝色线条代表真实值，红色线条代表预测值。图中的RMSE（均方根误差）为6.3644，这一较低的误差值表明模型具有较高的预测精度。从图中还可以观察到，大多数预测值与真实值紧密对应，尽管在某些样本点上存在一定的偏差。这种偏差可能是由于数据的

内在噪声或模型的泛化能力限制所导致的。然而，整体上，预测曲线与真实曲线的趋势保持一致，验证了PSO-BP模型在处理复杂非线性关系时的有效性。




图5 测试集预测结果对比

图6展示了模型在训练、验证和测试过程中的均方误差（MSE）变化情况。可以观察到，随着训练轮数的增加，MSE迅速下降并趋于稳定，最佳验证性能在第20个Epoch达到。这一结果表明，PSO优化的LSTM模型能够有效地学习数据特征，并在验证集上实现低误差。图中显示的训练、验证和测试误差曲线接近，说明模型具有良好的泛化能力，未出现明显的过拟合现象。此外，误差曲线的稳定性进一步证实了模型的鲁棒性。总体而言，本研究的模型在测试集上展现了较高的预测精度，为相关领域的预测任务提供了一种有效的解决办法。




图6 均方差变化曲线

4 结论

为了准确预测空气中的PM2.5浓度，本文在粒子群优化（PSO）寻优精度和效率的基础上，设计了一种优化的LSTM模型，进而构建新的PM2.5浓度预测模型。最后，通过配置最优参数的神经网络进行PM2.5浓度预测，有效避免神经网络训练时陷入局部最优，提升预测准确度。选取北京市附近10个地区大气气象数据作为样本进行实验分析，结果表明，PSO-LSTM模型通过智能优化超参数，有效解决了传统LSTM的局限性，为PM2.5浓度预测提供了高精度、高鲁棒性的解决方案，具有广阔的应用前景与环境价值，预测精度更高。进一步的研究可以考虑引入莱维飞行和混沌映射，优化PSO粒子群的多样性，从而进一步提升PM2.5浓度预测的精度。未来的工作可以探索该模型在不同数据集上的表现，并进一步优化算法参数以提升性能。

参考文献

[1] ZHOU B H, WANG J, LIU S X, et al. Extrapolation of an Thropogenic Disturbances on Hazard Elements in PM2.5 Inatypical Heavy Industrial City in Northwest China [J]. Environmental Scienceand Pollution Research International, 2022, 29 (43) : 64582-64596.

[2] 吴婷婷 . 兰州市城区大气 PM2.5 对心血管疾病入院人数的影响及对心肌细胞损伤机制研究 [D]. 兰州: 兰州大学, 2022.

[3] YI YANG HU, HAI BIN LIAO, LI YUAN, et al. MTLPM: A Long-Term Fine-Grained PM2.5 Prediction Method Based on Spatio-Temporal Graph Neural Network [J]. Environmental Monitoring and Assessment, 2024, 196 (12) : 1240-1240.

[4] 杨新兴, 冯丽华, 尉鹏 . 大气颗粒物 PM2.5 及其危害 [J]. 前沿科学, 2012, 6 (1) : 22-31.

[5] 刘晓剑, 吴永胜, 付英斌, 等 . 深圳市空气 PM2.5 与 心脑血管疾病死亡的广义相加模型分析 [J]. 中华疾病控制杂志, 2016, 20 (2) : 207-209.

[6] 王媛媛, 沈俞, 陈秀川, 等 . 基于改进时空因果卷积网络的 PM2.5 浓度预测 [J]. 自动化技术与应用, 2025, 44 (2) : 21-25.

[7] 丁成亮, 郑洪波 . 基于改进机器学习的 PM2.5 浓度预测模型研究 [J]. 大连理工大学学报, 2024, 64 (4) : 353- 360.

[8] 林买金, 张露露, 唐友兵, 等 . 基于 CNN-GRU-SSA组合模型的 PM2.5浓度预测 [J]. 科学技术与工程, 2024, 24 (31) : 13269-13276.

[9] 张丹宁, 吴巧丽, 张博 . 基于 BP 神经网络的 PM2.5 浓度值预测模型 [J]. 建材技术与应用, 2023 (2) : 9-13.

[10] ZHANG S Q, ZHOU H Y. Beijing Population Migration Analysis Based on WPD-BP Neural Network [C]// Proceedings Volume 12510, International Conference on Statistics, Data Science, and Computational Intelligence (CSDSCI 2022). Chongqing: SPIE, 2023: 1-5.

[11] 彭豪杰, 周杨, 胡校飞, 等 . 基于深度学习与随机森林的 PM2.5 浓度预测模型 [J]. 遥感学报, 2023, 27 (2) : 430- 440.