



工程优化技术期末大作业

基于改进 Retinex 和 YOLOv8 算法的复杂光照环境行人检测

姓 名	胡玉春
学 科 专 业	机械
学 号	S2402W0262
研 究 方 向	拓扑优化
学 院	机械与运载工程学院
上 课 教 师	王琥

摘要

随着科技的发展,自动驾驶技术逐渐部署在各车辆上,自动驾驶系统视觉感知问题受到广泛关注。视觉感知部分主要依赖车载摄像头采集数据和系统实时对图片的分析,从而分辨出车外界的行人、障碍物、交通标识等信息。现如今复杂光照下的行人检测是行人检测任务中常见的挑战之一。通用的行人检测方法在一些复杂的光照环境下(如低光、阴影等)性能不佳。针对复杂光照环境中摄像头采集到的图像特征信息不明显、难学习等问题,提出了一种基于 Retinex-Net 图像增强算法和改进 YOLO 算法的融合模型 RA-YOLO。具体工作如下:

(1) 采集了复杂光照环境下的行人数据,通过对图像进行清洗、标注等工作转化成供后续训练的图像/标签对,再与开源数据集 ExDark 融合后得到涵盖场景更多的 ExDark-H 数据集。

(2) 研究了复杂光照环境的图像增强算法,基于 Retinex-Net 基本模型,在其分解网络和增强网络中分别添加注意力机制,加强对低光照图像中细节特征的提取。在 LOL 低照度数据集上进行训练验证了改进网络的可行性,通过消融实验分析了分解网络和增强网络的作用。

(3) 基于 YOLOv8 网络,对 C2f 模块进行改进,引入了深度可分离卷积模块,同时在 C2f 和多个卷积层后添加 CBAM 注意力机制,将优化的图像增强算法和改进的 YOLO 算法融合,构建出复杂光照环境行人检测模型 RA-YOLO。

结果表明,本文提出的图像增强模型 Retinex-Attention 取得了较高的 PSNR 和 SSIM 指标。融合后的模型 RA-YOLO 在多个测试集上均表现优秀。

关键词: 图像增强; 机器视觉; 行人检测;

Abstract

With the advancement of technology, autonomous driving technology is gradually being deployed in various vehicles, and the visual perception of autonomous driving systems has attracted widespread attention. The visual perception part mainly relies on the data collected by onboard cameras and the real-time analysis of images by the system to distinguish pedestrians, obstacles, traffic signs, and other information outside the vehicle. Nowadays, pedestrian detection under complex illumination is one of the common challenges in pedestrian detection tasks. General pedestrian detection methods perform poorly in complex illumination environments (such as low light, shadows, etc.). In response to the problems of less obvious image feature information and difficulty in learning captured by cameras in complex illumination environments, a fusion model called RA-YOLO based on the Retinex-Net image enhancement algorithm and the improved YOLO algorithm is proposed. The specific work is as follows:

(1) Pedestrian data under complex lighting conditions were collected. Through processes such as image cleaning and annotation, the data were converted into image/label pairs for subsequent training. These were then merged with the open-source dataset ExDark to form the ExDark-H dataset, which covers a wider range of scenarios.

(2) The image enhancement algorithm for complex illumination environments was studied. Based on the basic Retinex-Net model, attention mechanisms were added to both the decomposition network and the enhancement network to strengthen the extraction of detail features in low-illumination images. The improved network was trained and validated on the LOL low-illumination dataset, and the roles of the decomposition network and the enhancement network were analyzed through ablation experiments.

(3) Based on the YOLOv8 network, the C2f module was improved by introducing a depth wise separable convolution module. CBAM attention mechanisms were also added after the C2f module and multiple convolutional layers. The

optimized image enhancement algorithm and the improved YOLO algorithm were integrated to construct the RA-YOLO model for pedestrian detection under complex illumination environments.

The results show that the proposed image enhancement model Retinex-Attention achieved high PSNR and SSIM indicators. The fused model RA-YOLO performed excellently on multiple test sets.

Key words: Image Enhancement; Machine Vision; Pedestrian Detection

目录

1、介绍	1
2、数据集建立	4
2.1 LOL 数据集概述	4
2.1.1 LOL 数据集的特点和应用	4
2.2 自采集行人检测数据集	5
2.3 融合数据集 ExDark-H	5
3、基于 Retinex-Net 理论的图像增强网络	7
3.1 Retinex 算法基本原理	7
3.2 改进的模型结构 Retinex-Attention	8
3.2.1 注意力机制	8
3.2.2 改进的分解网络	10
3.2.3 改进的增强网络	11
3.3 模型评估	11
3.3.1 评价标准	11
3.3.2 实验设置	12
4、图像增强与改进 YOLOv8 融合的行人检测	15
4.1 YOLOv8 算法	15
4.2 改进的 YOLOv8-DSC-CBAM 模型	15
4.2.1 改进的 C2f 模块	15
4.2.2 YOLOv8-DSC-CBAM 网络	16
4.3 YOLOv8-DSC-CBAM 模型实验结果分析	17
4.4 RA-YOLO 模型行人检测实例	18
5、总结	19
参考文献	20

1、介绍

在智能化和物联网飞速发展的时代，计算机视觉领域在不断创新和发展，图像和视频数据的大量提升帮助算法不断迭代。随着现代人工智能技术的发展，行人检测技术逐渐成为研究的热点。行人检测是在计算机视觉的基础上针对行人的检测任务，广泛应用于智能监控、自动驾驶、安防监控、人脸识别、智能交通等领域。随着智能网联的发展，行人检测技术在公共安全、交通管理以及人机交互等场景中发挥越来越重要的作用。

在实际应用方面，基于深度学习的行人检测有很高的落地应用价值，它可以进行行人跟踪、行人重识别等相关工作。行人检测在实际生活中有着多方面的应用：1) 监控安防领域；2) 自动驾驶领域



图 1.1 行人检测相关应用领域

行人检测的发展大致经历了两个阶段：传统物体检测方法、基于深度学习的检测。2001 年 P.Viola 和 M.Jones 提出了著名的 VJ 检测器[1]，采用积分图像技术，提升了检测效率和精度。2005 年，Dalal 和 Triggs 提出了 HOG (Histogram of Oriented Concentrants) 特征描述符[2]，将 HOG 描述符设计为密集均匀间隔的单元格上计算，还构建了 INRIA 行人数据集。2008 年，Felzenszwalb[3]提出了行人检测算法，该算法可以将行人划分成不同的部分进行训练和学习，也可以在分类的时候将其视为不同部分检测的集合，在这种思想下，该算法及其改进算法连续几年取得了最好的检测效果。传统的目标检测方法实现过程类似于 VJ 检测器，主要通过人工设计来提取目标特征 (HOG, Haar 和 SIFT) 和新的提取方法[4]，并进一步使用 SVM, DT[5]和其他分类器进行识别和检测。检测前一般先对图像预处理提升其质量[6]，在检测过程中，还会对图像做滑动窗口处理，这样做检测性能可以达到最佳。

目前，基于深度学习的目标检测方法主要形成了两种典型范式：（1）采用

区域建议与分类回归相结合的两阶段检测框架，生成可能对象的候选区域后进行进一步分类和定位；（2）一阶段处理方法，直接返回特征图上的目标区域，给出最终的预测结果。

一阶段检测框架去除了先验框生成部分，直接通过在特征图上设置一系列锚点来预测对象中心和对象边界框。2015 年，Redmon 等人提出了深度学习时代首个单阶段检测器 YOLO[7]。YOLO 采用单神经网络对整幅图像进行端到端检测，将图像划分成多个网格，分别对每个网格进行分析，计算边界框和类别概率。在行人检测任务中，尤其是智能驾驶技术的行人检测中，检测速度尤为重要。一级检测框架的速度加快为此提供了可能。不过，YOLO 算法在目标定位精度方面存在一定局限性，主要原因是该算法仅在预设的锚点位置进行目标预测。这种设计导致算法在处理小目标和群体检测任务时表现欠佳。

针对以上问题，Redmon 又提出了 YOLOv2[8]和 YOLOv3[9]，它们对 YOLO 算法进行了优化，提高了一级检测器的速度，还提高了精度。2020 年，AlexeyBochkovskiy 提出了 YOLOv4[10]，其中添加了 SPP 结构[11]和 PAN 结构[12]；相继 YOLOv5 算法由 Ultralytics 团队提出，相较于 v4，它的代码更简洁，易于部署。2021 年 MeituanAI 团队提出了 YOLOv6，v6 是 YOLO 系列轻量化的一个版本，其中引入了新的模型架构，减少了参数量，并通过优化训练过程，进一步提高了检测精度和推理效率。2022 年 Wang 等人提出了 YOLOv7 算法，通过训练 Bag-of-Freebies 来增强模型表现，提升了模型的检测精度和训练速度，在速度和精度之间达到了平衡。YOLOv8 采用了无锚框（Anchor-Free）的方法，在多任务学习和自适应优化方面做出了创新。Wang 等人提出 YOLOv9[13]，使用可编程梯度信息（PGI），用于在深层神经网络中保持数据的完整性和稳健的梯度，防止数据退化；此外，清华大学团队引入整体效率—精度驱动的设计策略，推出 YOLOv10。Ultraytic 又在 2024 年发布了 YOLOv11 版本算法，在 YOLOv8 的基础上又进行了改进，支持多种视觉任务[14]。

其中 YOLOv8 网络独特的 C2f 多分支特征融合模块能有效聚合暗光细节与语义信息，结合低光自适应数据增强模拟动态光照干扰，并通过动态标签分配强化模糊目标的梯度权重，在暗区行人检测精度较高，兼顾复杂光照场景的实时性与鲁棒性。

在实际应用中，如自动驾驶车辆在复杂光照调节下行驶过程中，需要行人和其他物体的准确定位信息，才能进行后续的规划控制模块。然而在现实很多场景中，图像的质量难以保证，图像失真的现象很常见。而 Retinex 算法，能实现图像亮度和对比度提升，故针对在复杂光照的场景下，行人检测面临采集图像亮度低、特征模糊不清等问题，提出了一种基于 Retinex-Net 图像增强算法和改进 YOLO 算法的融合模型 RA-YOLO，在增强图像的质量的同时，提高了在复杂光照场景下的行人检测能力。

全文基于复杂光照环境下的行人检测技术进行研究，主要内容分为以下几个部分：第 1 章，介绍；第 2 章，数据集介绍；第 3 章，基于 Retinex-Net 算法的改进和优化；第 4 章，YOLOv8 行人检测算法的研究与改进；第 5 章，总结。

2、数据集建立

2.1 LOL 数据集概述

选用了开源的 LOL 数据集作为图像增强任务中的数据集。LOL 数据集是一个专门用于低照度图像增强研究的基准数据集，其中包含了丰富的低照度图像样本，并为每张低照度图像提供了对应的正常光照参考图像。该数据集的设计旨在模拟低光照强度环境下，特别是在夜间或阴影下，图像质量通常会遭受到严重的损失，导致行人识别和其他视觉任务难度的增加。为了提高复杂光照环境下图像识别的可能性，研究者通常会使用图像增强方法来恢复图像的细节和亮度。

LOL 数据集中有 500 对低光照和正常光照图像，为图像增强研究提供了高质量的训练和测试数据。其中划分为 485 对训练图像和 15 对验证图像，所有图像分辨率均为 400×600 ，如图 2.1 所示。每一对图像都包括相同场景的正常光照图像与低光照图像，以便对比和验证低光照条件下图像质量的恢复效果。



图 2.1 LOL 数据集正常光与弱光对比

2.1.1 LOL 数据集的特点和应用

LOL 数据集的主要特点是其图像对比性强、光照条件变化大，涵盖了多种复杂环境光照情况。主要分为两大类：

- (1) 正常光照图像在视觉效果良好的光照条件下拍摄，图像细节清晰，质量较好。
- (2) 低光照图像在低光照或者暗光等复杂光照环境下拍摄，图像较为暗淡且细节丢失，噪声较多。

这些图像可以模拟光照条件差的图像质量问题，特别是在行人检测中，低光照条件下图像的对比度和亮度通常较差，难以提取足够的特征用于识别。因此，使用 LOL 数据集可以帮助评估本研究中提出的基于改进 Retinex 算法的图像增强

方法在人群检测和行人识别中的有效性。

2.2 自采集行人检测数据集

随着行人识别技术的发展,现有的开源数据集虽然在一定程度上覆盖了行人的基本特征和一些典型的场景,但往往存在一些局限性。许多开源数据集中的图像主要集中在光照均匀的环境下,难以有效模拟复杂光照变化(如阴影、背光、低光照等情况);也有些数据集中标注质量不高,造成算法训练和评估误差增大;现有数据集通常是在标准化、相对简单的环境下采集,缺乏在实际应用中经常遇到的复杂光照和背景干扰。为了解决这些问题,本研究决定采集一个包含多种复杂光照条件下行人的自采集数据集。

本文采集数据的设备为生活中常见的摄像头。数据采集分不同时间段和不同环境,包括城市街道、停车场、校园和室内长廊等。每一个场景下也会模拟不同的光照条件,例如,阴影区域、背光场景、傍晚等低光条件。为了获取多样化的光照图像,数据采集工作分为白天和夜晚进行。白天采集的数据涵盖不同时间段,以应对日照变化;夜间采集主要针对低光照场景,重点考察在夜晚的低光照条件下行人的识别效果。部分图像如图 2.2 所示:



(a) 阴影

(b) 弱光

(c) 夜间多光照

图 2.2 采集数据展示

数据采集完成后,进行图像标注,标注的内容包括:行人的位置、行人的类别(例如,成人、儿童、骑车者等)以及光照条件的标签(正常光照、阴影、背光、低光照等)。

完成数据采集和标注后,构建了一个包含约 1000 张图像的数据集,这些图像涵盖了不同光照条件、不同姿势和背景下的行人。

2.3 融合数据集 ExDark-H

为验证改进后行人检测算法的性能，后续选用常见的低光行人检测数据集 ExDark[15]和本文采集的复杂光照行人数据集融合组成 ExDark-H，用于评估算法的精度。ExDark 数据集中包含了大量的光照条件的行人，且涵盖多个场景，广泛用于行人检测的训练和评估。

ExDark (Extreme Low-Light Dataset for Object Detection and Recognition) 是一个专门针对极端低光照环境的目标检测和识别数据集。Loh 等人在 2019 年构建了 ExDark 数据集，目的是应对计算机视觉任务在低光环境性能下降的挑战。数据集中涵盖了多种场景下的低光图像，广泛应用于目标检测、图像分量和低光照行人检测等任务。由于该数据集包含了大量的低光照环境下的行人目标，因此在复杂光照环境行人检测研究中有重要价值。主要由 7363 张低光照图像组成，包括训练集 5891 张，测试集 1472 张，12 个类别。图像均来自于不同的真实场景，涵盖了各种低光照环境，例如夜间、室内灯光不足、阴影覆盖等。12 个类别中包括 person、bicycle、car 等。本文主要针对 person 类别展开检测工作。

自采集数据集包括多种场景，比如十字路口、三岔路口、校园中、停车场等行人常出现的场景，将这些数据与处理过的 ExDark 数据集进行融合，得到涵盖场景范围更广的数据库，也包括更多时间段的图像。

表 2.1 数据集统计与特性

属性	ExDark	自采集数据	ExDark-H
图像总数	7363	1000	8363
行人数	3500	2370	5870
光照场景类型	低光照	混合光照	低光照、混合光照
主要挑战	暗光、低对比度	逆光、阴影	暗光、光晕干扰、模糊

3、基于 Retinex-Net 理论的图像增强网络

行人检测是自动驾驶中的一个重要任务，但在夜间行驶时，路上的行人很难准确识别。当摄像头在低光环境中采集到对比度低、细节丢失等问题的图像时，会影响自动驾驶系统对行人识别的准确率，对自动驾驶整个系统都造成了严重的困扰。而 Retinex 算法可以通过引发提示影响，增强图像中的细节，使得行人在图像中的特征更加突出，从而提高行人检测的准确性。

3.1 Retinex 算法基本原理

Retinex 理论[16] 最初由 Land 和 McCann 提出，该理论强调在视觉信息处理过程中消除光照对物体本质特征的影响。Retinex 方法通过独特的处理机制改善了图像的视觉质量。如图 3.1 所示，该算法采用多尺度高斯滤波对输入图像进行处理，随后进行色彩恢复操作。其核心思想是将图像分解成反射分量和光照分量两个部分，通过对这两个分量进行处理，最终实现低照度环境下图像质量的显著提升。




图 3.1 Retinex 原理模型图

如图 3.1 所示，观察者所看到的图像 $S(x,y)$ 是由入射图像 $L(x,y)$ 和反射图像 $R(x,y)$ 构成。即入射光照射在反射物体上，通过反射物体的反射，形成反射光进入人眼，从而形成图像；Retinex 理论公式如式 1 表示：

$$S(x, y) = R(x, y) \cdot L(x, y) \quad (3.1)$$

Retinex 算法的核心就是估测入射图像 $L(x,y)$ ，从图像 $S(x,y)$ 中来估 $L(x,y)$ 分量，并去除 $L(x,y)$ 分量，从而得到反射图像 $R(x,y)$ 。具体操作：

对公式 1 两边同时取对数：

$$\log [R(x, y)] = \log [S(x, y)] - \log [L(x, y)] \quad (3.2)$$

进一步推导后得到 Retinex 理论的核心公式 (3)

$$r(x, y) = \log(R(x, y)) = \log(S(x, y)) - \log(L(x, y)) \quad (3.3)$$

令 $S(x, y) = \log(S(x, y))$, $I(x, y) = \log(L(x, y))$ 得到公式 (4)

$$r(x, y) = s(x, y) - I(x, y) \quad (3.4)$$

Retinex 算法在图像增强领域取得了显著成果,有效提升了图像增强的能力。但仍存在一些不足:(1)对噪声敏感;(2)色彩失真;(3)无法处理极端光照条件;(4)参数选择问题。为了克服这些缺陷,许多改进方法应运而生,其中包括基于深度学习的 Retinex 方法、多尺度 Retinex 方法等。相比之下 Retinex-Net 在处理速度上表现优秀,能够在无需手动调整参数的情况下获得较好的增强效果;但还存在较大的噪声问题,并伴随一定的色彩失真。本文在 Retinex-Net 基础上进行了优化。

3.2 改进的模型结构 Retinex-Attention

本文基于通道注意力机制和空间注意力机制,对 Retinex-Net 进行改进,改进后的网络命名为 Retinex-Attention。

3.2.1 注意力机制

本文引入了注意力机制,使网络能根据任务需求自适应调整各通道的权重分配,从而提升模型的特征选择能力,更注重图像的关键部分,如颜色、纹理、形状等,减少对图像中无关特征的注意,获得更加精准的图像增强效果。

注意力机制模拟人类视觉注意力的机制,关注图像中的重要区域,增强模型对重要特征的感知和处理能力。在图像处理和计算机视觉等领域,注意力机制逐渐成为提升模型性能的关键技术,特别是在处理复杂任务时,比如图像增强、物体检测等方面。通过赋予不同区域和特征不同的权重,注意力机制添加到网络中可以使其聚焦于图像的关键部分,忽略不相关或者不重要的区域,提高网络的效率和准确性,提升网络处理图像亮度和细节保留等方面的能力,从而获得更加精准的图像增强效果。

本文引入了两种注意力机制,既关注空间维度,也关注通道维度,从而更好地提升图像的细节和纹理表现。

(1) 通道注意力机制

通道注意力机制(Channel Attention Mechanism,CAM)是一种在深度学习中增强特征表现的关键技术,通过对特征图中不同通道进行学习,突出对任务有用的特征,抑制噪声通道。

作为通道注意力机制的代表模型,SENet 采用了一种创新的双模块结构,首先压缩模块对输入特征图的全局空间信息进行降维处理,然后激励模块通过通道维度的特征学习,通过自适应学习机制获取特征权重后,将原始输入特征与计算所得的重要性权重进行逐元素乘积运算,生成增强后的特征图。可以有效地对不同地特征通道进行区分和加权,提升了网络对图像重要特征的敏感性。其结构如图 3.2 所示:




图 3.2 SEblock 结构

(2) 空间注意力机制

空间注意力机制 (Spatial Attention Mechanism, SAM) 主要关注特征图中空间的内部关系,聚焦特征图上的有效信息在“哪里”。STN (Spatial Transformer Network) 网络是空间注意力机制的代表模型,该机制能实现面向特定学习任务自适应预处理,网络结构如下:




图 3.3 STN 结构

输入的特征图 U 被局部网络处理得到参数 θ , 然后经过网络生成器得到采样

器，映射到原图，得到输出 V 。

3.2.2 改进的分解网络

在第二层和第四层卷积层之后加入 SEBlock 注意力块，最后利用卷积层和 Sigmoid 函数进行输出。网络结构如图 3.4 所示。




图 3.4 改进的 Decom-Net 网络结构

改进之后的分解网络中，第一层为 3×3 的卷积层，用于提取输入图像的特征。二、三层在卷积层的基础上，加入了 ReLU 激活函数，在第四层加入 SEBlock，提升通道特征的自适应学习能力。后续 3×3 的 Conv 层将反射和光照分量提取出来，经过 Sigmoid 层，将输出控制在 $[0, 1]$ 内。

在第二个 Conv+ReLU 后加入 SEBlock，目的是增强中间层的特征学习能力。在第二个 Conv+ReLU 之后，网络已经提取了一部分基础特征，但是这些特征仍然包含较多的低级信息，如边缘和局部亮度差异。这个阶段加入 SEBlock 可以适应地增强关键通道，提高网络对光照和反射特征的区分能力，使光照估计更加准确。在第四个 Conv+ReLU 后，网络的深层特征已经提取出了完整的光照和反射信息，在这层引入 SEBlock，可以进一步优化通道间的特征表达，使网络更加关注图像的亮度分布和物体细节，从而提高最终分解精度。

SEBlock 注意力块通过自适应通道权重调整，增强对分解任务关键特征的关注。其中全局平均池化压缩空间信息，生成通道描述向量；全连接层学习通道间依赖关系，生成归一化权重；权重与原特征图相乘，强化重要通道，抑制噪声或冗余通道。在 Retinex 理论中，分解网络需要分离出图像中的反射分离和光照分量，嵌入 SEBlock 后，动态调整权重的方法增强了对光照敏感的通道，更能突出反射相关的细节通道，并且能抑制噪声或者干扰通道。通过对光照分量的优化，分解网络能抑制光照中的过曝区域，使图像更加平滑，提升分解精度。其次模型对场景的自适应能力增强，SEBlock 权重动态调整使网络适应不同的光照条件，

减少了对固定数据分布的依赖，提升了对复杂场景的泛化能力。同时通道注意力机制帮助网络训练在反向传播时更聚焦关键通道，加速模型的收敛。

3.2.3 改进的增强网络

增强网络的目的是增强图像的亮度、细节和对比度，原有的 Retinex-Net 存在颜色失真，本文为有效解决颜色失真问题，对 Retinex-Net 的增强网络进行优化，在其中添加空间注意力机制。在增强网络对低光照图像进行增强时，通过空间注意力机制关注某些特别重要的区域，比如行人或者物体。

在 Enhance-Net 中卷积操作之前加入 STN 空间注意力机制。STN 的作用是在图像进入深层卷积网络之前作为预处理模块，首先对图像进行空间变换，STN 会根据图像的内容调整图像的空间结构，帮助模型更好聚焦于图像的关键部分。在空间变换之后，图像再进入增强网络的卷积层，这些卷积层会提取更加明显地特征，并进行亮度、对比度等增强操作。最终经过多个卷积层和非线性激活函数 ReLU 的作用，得到最后的输出。具体改进的网络结构如图 3.5 所示。




图 3.5 改进的 Enhance-Net 结构

3.3 模型评估

3.3.1 评价标准

在本文中，选用峰值信噪比（PSNR）用于量化图像的信噪比水平，结构相似度指数（SSIM）用于评估图像结构的保持程度，这两个参数可以良好地对图像增强效果进行评价对比。

PSNR 是图像质量评估领域的重要量化指标，用图像的信号能量与噪声能量之间的比值作为衡量图像质量的标准。噪声评价能量通过均方误差（Mean Squared Error, MSE）计算，即测量真实值与噪声图像之间的像素差异。PSNR 值越大，图像质量越好，代表图像和原始图像的相似度更高。

SSIM 通过亮度、对比度和结构信息的比较来评估图像质量，它直接计算待测图像与参考图像之间的相似度来量化图像的结构损失；其量化结果介于-1 至 1 之间，其数值大小与图像质量改善程度呈正相关关系，当计算结果趋近于 1 时，表明经过处理的图像在视觉效果方面达到最优水平。

3.3.2 实验设置

为了充分验证本章改进后算法的可行性，将改进后的算法分别使用融合数据集 ExDark-HN 和 LOL 低光数据集进行训练、测试。在融合数据集中，随机选择其中 200 张图片进行测试；在 LOL 数据集中，随机选择 200 张图片进行测试。通过在 LOL 数据集上测试对比增强前后的图像，验证其图像增强性能；在 ExDark 数据集上随机抽取的低光照图像可以对模型的泛化性能进行评估。

对 Retinex-Attention 算法的主要模块进行消融实验，分别是 Decom、Enhance 模块。使用原始的 Retinex-Net 作为对照组，然后将本章改进的 Decom 和 Enhance 模块分别与其替换组成新的网络结构，依次训练进行对比。对比结果如表 3.1 所示。

表 3.1 消融实验

网络框架	PSNR	SSIM
Retinex-Net	27.99	0.6049
Retinex-Net+Decom	28.14	0.6402
Retinex-Net+Decom+Enhance	28.70	0.6949

可以看到：原始网络 Retinex-Net 在加入改进的分解模块后，PSNR 和 SSIM 指标有小幅度的提升，说明在 Decom 模块中添加注意力机制 SEBlock 是有作用的。在加入 Enhance 模块后，两个评价指标都得到了提升，说明通过改进分解模块和增强模块，Retinex-Net 在上得到了优化。通过观察图 3.6，我们可以肉眼更直观的看到图片质量的提升。



(a) 原始图



(b) Retinex-Net



(c) Retinex-Net+Decom



(d) Retinex-Net+Decom+Enhance

图 3.6 消融实验对比


通过系统的消融实验验证，Retinex-Attention 算法在处理低照度图像时展现出显著的性能优势；这里再对同一低光图像采取不同的算法对其进行图像增强，观察效果。对比算法采用经典的 SSR、Retinex-Net。增强的效果如图 3.7 所示。



(a) 原图



(b) Retinex-Net



(c) SSR



(d) Retinex-Attention

图 3.7 不同算法对图像的处理效果对比

图中可以看到。经过 SSR 算法处理后的图像亮度变高，但是存在曝光、颜色失真、噪声放大的情况；Retinex-Net 算法中由于确实有效抑制噪声的模块，导致出现了一些噪声点。本文提出的算法在处理图像时，考虑了明暗区域之间的平衡关系，避免了色彩失真问题，有效抑制了噪声。处理后的图像色彩自然，较好地保持了场景的真实性。

主观判断容易受自身因素影响，所以接着在测试集上选取 300 张不同的图像，计算了不同算法的 PSNR 和 SSIM 进行比较，结果如表 3.2 所示，可以看到改进后的算法在评价指标上具有明显优势，无疑这为行人检测提供了良好的数据预处理。

表 3.2 不同的算法在 LOL 数据集上的对比

算法模型	PSNR	SSIM
SSR	27.70	0.3851
Retinex-Net	28.63	0.6029
Retinex-Attention	29.89	0.6421

4、图像增强与改进 YOLOv8 融合的行人检测

4.1 YOLOv8 算法

YOLOv8 的整体架构由三大核心组成部分构成，如图 4.1，依次为特征提取骨干网络（Backbone）、特征融合颈部网络（Neck）以及预测输出检测头（Head）。




图 4.1 YOLOv8 网络结构

当输入图像进入网络后，骨干网络通过多层卷积运算提取具有丰富语义信息的深度特征，构建多层次视觉金字塔。颈部网络通过特征金字塔结构和双向跨尺度连接机制，对来自不同深度的特征图进行自适应融合与尺度变换，实现多层次特征的有机整合，丰富特征表达能力，以适应不同尺寸目标检测需求。最后检测头根据提取到的多尺度特征图，在各位置上执行分类与边界框回归任务，生成最终预测结果。

4.2 改进的 YOLOv8-DSC-CBAM 模型

4.2.1 改进的 C2f 模块

本文对 YOLOv8 中的骨干和颈部网络进行改进，C2f 块是 YOLOv8 网络特征提取的核心模块。标准的 C2f 块中 Bottleneck 使用了两个 3×3 的卷积，尽管可以提取较多特征，但是参数量较大。本文引入一种深度可分离卷积替代标准的 3×3 卷积，提升模型推理速度，并将其命名为 Light-C2f 块。

深度可分离卷积是一种轻量级的卷积操作，其卷积过程分为两个部分，深度

卷积和逐点卷积。其中深度卷积用于提取空间特征，逐点卷积用于提取通道特征，在最终输出前使用一个 1×1 的卷积将所有通道进行融合。它对每个通道进行深度卷积及合并所有通道逐点卷积的过程，减少了模型的计算量，提升了计算效率。

改进前后的效果对比如表 4.1 所示：

表 4.1C2f 块改进前后 YOLOv8 测试时间和参数对比

算法	CPU (ms)	GPU (ms)	Params	mAP (%)
YOLOv8	450	9.6	55	70.94
YOLOv8+Light-C2f	410	8.7	40	69.41

上述测试在 ExDark-H 数据集中进行，C2f 改进后平均精度略低于原 YOLOv8 网络，但显著提高了模型的检测速度。

4. 2. 2YOLOv8-DSC-CBAM 网络

为解决对 Light-C2f 模块优化后网络精度下降的问题，本文在 YOLOv8 的整体网络结构中还嵌入了 CBAM（Convolution Block Attention Moudle）注意力模块，

CBAM 是一种结构简单高效的注意力机制，是一种轻量级注意力模块，其设计目标是在不显著增加模型复杂度的前提下，增强特征表达能力，帮助网络更高效地整合信息，从通道和空间两个维度提取特征，更好组建图像的细节。CBAM 中融合通道和空间注意力机制，既可以通过通道注意力学习各通道的关联性，也可以注意到空间维度上的特征，其在保持开销小的情况下有相当大的提升。CBAM 注意力机制的结构如图 4.2 所示。将其嵌入 YOLOv8 网络中，不会增加太多的复杂度。

通道注意力模块通过对输入特征图在通道维度上的加权处理，使网络能够聚焦于与行人类别高度相关的特征，提升了网络对行人目标的识别能力，减少漏检现象的发生；而空间注意力模块则作用于特征图的空间维度，通过捕捉位置编码等空间信息，增强了模型对目标位置信息的感知能力，降低了误检的概率。将这两个模块按顺序串联后，CBAM 可以动态调整特征的权重分布，在不同特征之间实现强化与抑制，增强了整体检测性能。




图 4.2 CBAM 模型概述

总的来说，优化后的 YOLOv8-DSC-CBAM 网络结构，可以更好地保留关键信息，特征不会在初步特征提取阶段消失，从而提高图像的清晰度，并且在特征融合过程中，CBAM 模块可以更好的聚焦关键特征，提高模型在复杂光照环境下的稳定性和鲁棒性。改进后的 YOLOv8-DSC-CBAM 网络如图 4.3 所示。




图 4.3 YOLOv8-DSC-CBAM 网络结构

4. 3YOLOv8-DSC-CBAM 模型实验结果分析

对改进的模型 YOLOv8-DSC-CBAM 与 YOLOv5、YOLOv7、YOLOv8 原模型在 ExDark-H 数据集上进行对比试验，检验改进模型的性能。实验中采用的评价指标为 Precision、Recall 和 mAP（mean Average Percision）。对比结果见表 4.2。

表 4.2 ExDark-H 数据集上模型性能参数对比

算法	Precision	Recall	mAP
YOLOv5	0.6740	0.6307	0.6056
YOLOv7	0.7312	0.7405	0.6664
YOLOv8	0.7894	0.8015	0.7095
YOLOv8-DSC-CBAM	0.8064	0.8195	0.7233


可以看到，改进后的模型在 Precision、Recall 和 mAP 三个关键指标上均实

现了显著提升。对比基准 YOLOv8 模型，改进的模型 Precision 提高了 1.7 个百分点；Recall 指标提高了 1.8 个百分点；mAP 提高了 1.38 个百分点；证明了模型的优越性，为后续融合模型 RA-YOLO 的性能提升奠定了基础。。

4. 4RA-YOLO 模型行人检测实例

将 YOLOv8-DSC-CBAM 模型与 Retinex-Attention 模型进行融合后，使用相同的 Ex-Dark 测试集通过融合模型 RA-YOLO 进行测试，让待检测图像经过图像增强后再通过 YOLOv8-DSC-CBAM 进行检测，得出其 mAP 指标达到 78.86%，高于 YOLOv8-DSC-CBAM 模型 6.53%，显著提升了模型在复杂光照场景下的性能指标。

分别使用原始 YOLOv8 模型和本文的融合模型 RA-YOLO 对同一场景下的行人进行检测，如图 4.4 所示。从图中可以看出，在没有图像增强模型 YOLOv8 的检测下，一共识别到 6 位行人，部分行人不能检测到；而本文的 RA-YOLO 融合模型可以识别到 9 位行人，可以很好地检测一些原本暗光环境下的行人，显著提升了实际复杂光照场景下的行人检测能力。



(a) YOLOv8 模型



(b) 融合模型

图 4.4 行人检测效果对比

5、总结

自动驾驶技术飞速发展，在控制成本减少激光雷达使用情况下，复杂光照环境下行人检测面临着重大困难。纯视觉方案的智驾系统逐渐增多，同时也存在诸多问题。在复杂光照场景下，通过摄像头采集的图像可能细节模糊、噪声较多，本文分别对图像增强方法和行人检测方法进行了研究，并搭建了两者的融合模型；具体内容如下：

（1）对 Retinex-Net 模型进行优化，采用了通道和空间注意力机制，在该模型的分解网络和增强网络上进行改进，提出 Retinex-Attention 算法，增强了算法对图像中细节特征的提取，提升了输出图像的整体视觉效果，为行人检测奠定了基础。

（2）对 YOLOv8 的网络进行改进，将贯穿网络的 C2f 模块进行了改进，使用深度可分离卷积替代其中的两个小卷积块，并减少了 C2f 中的 Bottleneck 数量，减小了模型的复杂度。同时在颈部和骨骼部分添加了 CBAM 注意力块，提高网络对行人关键特征的关注程度，结果显示改进的模型 YOLOv8-DSC-CBAM 表现出显著优势。

（3）对改进的两种算法进行融合，提出了 RA-YOLO 算法，有效地提升了复杂光照环境下的行人检测能力。

参考文献

- [1]P. Viola, M. Jones. Rapid object detection using a boosted cascade of simple features[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Kauai: IEEE, 2001, 11–18.
- [2]N. Dalal, B. Triggs. Histograms of oriented gradients for human detection[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. San Diego: IEEE, 2005, 886-893.
- [3]P. Felzenszwalb, D. McAllester, D. Ramanan. A discriminatively trained, multiscale, deformable part model[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. San Diego: IEEE, 2008: 1-8.
- [4]Q. Ke, J. Zhang, H. Song, et al. Big data analytics enabled by feature extraction based on partial independence[J]. Neurocomputing, 2018, 288: 3-10.
- [5]W. Wei, X. Li, J. Liu, et al. Study on remote sensing image vegetation classification method based on decision tree classifier[C]. In: Proceedings of the IEEE Symposium Series on Computational Intelligence. Orlando: IEEE, 2018, 2292-2297.
- [6]L. Zhang, P. Shen, X. Peng, et al. Simultaneous enhancement and noise reduction of a single low-light image[J]. IET Image Processing, 2016, 10(11): 840-847.
- [7]J. Redmon, S. Divvala, R. Girshick, et al. You only look once: unified, real-time object detection[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016, 779-788.
- [8]J. Redmon, A. Farhadi. YOLO9000: better, faster, stronger[C]. In: Proceedings of the 30th IEEE/CVF Conference on Computer Vision and Pattern Recognition. Honolulu: IEEE, 2017.
- [9]J. Redmon, A. Farhadi. YOLOv3: an incremental improvement[R]. arXiv:1804.02767, 2018.
- [10]B. A. Wang, C. W. Liao. Optimal Speed and Accuracy of Object Detection[R]. arXiv:2004.10934, 2020.
- [11]K. He, X. Zhang, S. Ren, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine

Intelligence, 2015, 37(9): 1904-1916.

[12]S. Liu, L. Qi, H. Qin, et al. Path aggregation network for instance segmentation[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2018, 8759-8768.

[13]C. Y. Wang, A. Bochkovskiy, H. Y. Liao. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[R]. arXiv:2207.02696, 2022.

[14]M. L. Ali, Z. Zhang. The YOLO Framework: A Comprehensive Review of Evolution, Applications, and Benchmarks in Object Detection[J]. Computers, 2024, 13(12): 336.

[15]Y. P. Loh, C. S. Chan. Getting to know low-light images with the Exclusively Dark dataset[J]. Computer Vision and Image Understanding, 2019, 178: 30-42.

[16]E. H. Land, J. J. McCann. Lightness and Retinex theory[J]. Journal of the Optical Society of America, 1971, 61(1): 1-11.