
工程优化方法大作业



HUNAN UNIVERSITY

学 生 姓 名 _____ 周佑聪

学 院 名 称 _____ 机械与运载工程学院

学 生 学 号 _____ S240200274

论 文 名 称 _____ 用于求解车间调度问题的

_____ 混合智能优化算法

2025 年 08 月 27 日

摘要

本研究针对制造业智能化转型中的关键挑战——车间调度问题（JSP），提出了一种创新的近端优化策略驱动的模式因算法（PMA），用于解决节能分布式混合流水作业调度问题（EADHFSP）。该问题具有 NP 难特性，涉及多工厂、多阶段并行机器配置及机器能耗差异等复杂约束。传统方法在动态和大规模场景下表现不佳，为此，本研究融合强化学习与元启发式算法优势，设计了包含改进型交叉算子、多模态变异策略和智能局部搜索的混合优化框架。算法采用作业序列和工厂分配两级编码，通过 PPO 强化学习动态选择 6 类专用局部搜索算子（如关键路径优化 CPNS 和能效敏感机器分配 ESMA），实现全局搜索与局部优化的协同。实验采用 50 工件/3 工厂/4 阶段的基准配置，结果表明：PMA 在完工时间（Cmax）优化上较传统遗传算法快 35.7%，最终获得 118.4 ± 4.7 分钟的 Cmax 和 $327.6 \pm 18.3 \text{kWh}$ 的总能耗，其帕累托前沿解集分布广泛（100-300 分钟，200-800kWh）且均匀性良好。研究创新性地建立了强化学习与进化算法的协同机制，为分布式绿色制造提供了高效决策工具，其混合智能框架也可推广至其他组合优化领域，具有显著的理论价值和应用前景。

关键词：车间调度，混合智能优化算法，近端优化策略，模式因算法

第1章 引言与算法简介

1.1 研究背景与意义

随着全球制造业向智能化、柔性化转型，生产调度作为制造系统的核心决策环节，其优化水平直接决定了生产效率、资源利用率和市场响应速度。车间调度问题（Job Shop Scheduling Problem, JSP），因其约束复杂、搜索空间巨大，被证明是典型的 NP 难（NP-hard）问题，一直是学术界和工业界面临的重大挑战。传统的优化方法在应对动态扰动和大规模问题时往往显得力不从心，因此，探索智能、高效、自适应的新型调度算法具有重要的理论价值和现实意义。

车间调度问题作为运筹学与工业工程领域的经典组合优化问题，其研究始于 20 世纪 50 年代。早期研究主要基于数学规划方法，如 Johnson 算法（1954）针对两机器流水车间问题提出了多项式时间最优解。随着问题复杂度提升（如 NP-hard 特性在 20 世纪 70 年代被证明），精确算法（如分支定界法、动态规划）难以应对大规模实例，促使研究者转向近似算法。

20 世纪 80 至 90 年代，启发式规则（如最短加工时间优先 SPT、最早交货期优先 EDD）成为实用主流，但其解质量有限。同期，元启发式算法兴起，模拟退火（SA）、遗传算法（GA）、禁忌搜索（TS）等通过全局搜索显著提升解质量。21 世纪以来，智能优化算法（如粒子群优化 PSO、蚁群算法 ACO）与混合策略（如将局部搜索与元启发式结合）成为研究热点。近年来，机器学习（尤其是强化学习）与数据驱动方法被引入，以自适应学习调度策略。

综上所述，现有的车间调度的解决方法主要有：

- 精确算法（数学方法）：使用整数规划，分支定界等方法求解，或使用 CPLEX, Gurobi 等数学求解器（内置上述方法）进行求解
- 启发式规则：基于简单优先级规则实时分配任务，如先入先出（FIFO）、最短加工时间（SPT）
- 元启发式算法：通过高层策略指导搜索过程，避免局部最优。
- 超级启发式算法：不直接操作解，而是选择或生成底层启发式规则
- 机器学习算法：利用历史数据训练模型（如神经网络）或通过 RL 代理学习调度策略

1.2 混合智能优化算法

元启发式算法在巨大的解空间中进行全局搜索，已被广泛证明能有效求解 JSP，并能在一定程度上获得近似最优解，然而这类方法通常计算成本较高，且

响应迟缓，缺乏实时决策能力。近年来，强化学习通过其强大的环境感知与序列决策能力，为动态调度提供了新思路。智能体通过与仿真环境交互，学习最优的调度策略，无需复杂的数学建模，然而其训练过程不稳定，探索效率低下，且容易陷入局部最优，在绝对解质量上有时难以超越经过充分优化的元启发式算法。

综上所述，单一策略各有其固有的优势与瓶颈。因此，将强化学习的在线决策优势与元启发式算法的全局优化能力相结合，形成混合智能调度框架，已成为当前研究的前沿趋势，本文设计的混合智能优化算法是一种结合元启发式算法和强化学习的混合算法，命名为近端优化策略驱动的模式算法。

1.2.1 模式算法及其瓶颈

模式算法（MA）是一种经典的基于 pareto 的多目标进化算法，其本质是遗传算法和局部搜索的混合架构，近年来在解决众多的车间调度问题中受到了极大的关注。模式算法通过平衡探索与利用来逼近问题的最优解。其中，局部搜索算子作为“利用”环节的核心，负责对当前解进行精细化改进，其性能直接决定了算法的收敛速度与解的质量。然而，一个长期存在的核心挑战是：“没有单一的局部搜索算子能在整个搜索过程的所有阶段始终保持最优性能”。此即著名的算法选择问题在元启发式内部的体现。

传统局部搜索算子的解决方案，如预定义算子序列、轮盘赌选择或基于简单统计（如近期改进次数）的选择策略，往往存在局限性：它们要么缺乏灵活性，无法适应不同问题实例；要么依赖专家经验，难以泛化；要么无法感知搜索进程的宏观状态，导致决策短视。

1.2.2 近端优化策略及其优势

强化学习（Reinforcement Learning, RL）作为一种框架，其智能体通过与环境交互并基于奖励信号学习最优策略，恰好为这一挑战提供了崭新的解决路径。将 RL 用于元启发式的算子选择，本质上是构建一个超启发式系统，其目标不再是直接产生解，而是动态地为底层元启发式算法选择或生成最合适的启发式规则（即局部搜索算子）。

近端优化策略（PPO）是一种深度强化学习中非常流行且高效的策略梯度方法，由 OpenAI 在 2017 年提出，迅速成为解决各类复杂问题的基准算法，并在车间的动态调度问题作为一种主力算法被广泛应用。PPO 通过直接学习一个策略函数（如神经网络），输入状态，输出选择各算子的概率分布，且 PPO 智能体作为高层控制器，在元启发式算法的每个决策点介入，根据当前状态选择算子，应用后观测结果并更新其策略。

1.2.3 近端优化策略驱动的模式因算法

综上所述，本文所设计的近端优化策略驱动的模式因算法（PPO-driven memetic algorithm, PMA）是 MA 在局部搜索的过程中利用 PPO 强化种群个体在局部搜索算子选择上的针对。

元启发式的搜索过程可被天然地建模为一个马尔可夫决策过程（MDP），状态可以用当前算法状态的特征化表示，如本文中采用模式因算法的染色体作为 PPO 算法的状态输入；动作可用的局部搜索算子集合。每个动作代表应用某个特定算子；奖励表示为应用所选算子后带来的即时性能反馈，本文表示为是否对本文的优化目标有所改进；策略抽象为一个从状态到动作的映射，即根据当前搜索状态决定下一步应采用哪个算子的规则，PPO 将会在算法运行中不断学习最优策略，最后根据种群个体的不同，选择最为合适的局部搜索算子。

第2章 问题描述

2.1 节能分布式混合流水作业介绍

节能分布式混合流水作业调度 (the energy-aware distributed hybrid flow-shop scheduling, EADHFSP) 是经典混合流水车间调度问题 (HFSP) 在分布式制造环境和节能制造环境下的扩展。该问题描述如下:

设有 f 个分布式工厂, 每个工厂内部包含一系列生产阶段。每个阶段 j ($j=1,2,\dots,m$) 配备一台或多台并行机器, 且机器的加工具有不同的能耗。现有 n 个待加工工件 ($i=1,2,\dots,n$), 每个工件需按相同的工艺路径依次经过所有生产阶段。在阶段 j 中, 工件需由该阶段的一台可用机器处理, 且不同机器产生的能耗水平不同。每个工件只能在一个工厂内完成全部加工过程, 且每个工厂具备独立处理所有工件的能力。调度目标是为每个工件分配合适的工厂, 并在各工厂内确定工件的加工顺序与机器分配, 以优化最小完工时间 ($C_{\max}$) 和最小能耗 (TED)。

此外, DHFSP-SDST 应满足以下假设: (1)每个工作只能分配给一家工厂。(2)所有工作必须按照给定的顺序在所有阶段进行加工。(3)在每个阶段, 一个作业只能分配给一台机器。(4)每台机器不能同时处理多个操作, 并且在同一机器上的两个连续作业之间考虑顺序相关的设置时间。(5)所有工厂的所有工作和机器都在零点可用。(6)所有机器上的第一个作业只有在初始调整完成后才能开始。(7)在所有机器上, 作业一旦启动就不能中断。(8)预先知道所有机器上所有作业的加工时间。

2.2 问题复杂度分析

EADHFSP 具有以下计算复杂性特征:

NP-hard 性质: 即使简化版本 (单工厂、同构机器、忽略能耗) 也已被证明是 NP-hard 问题。分布式和能效维度的加入进一步增加了问题复杂度。

解空间规模:

工厂分配方案: f^n 种可能;

工序排序方案: 工厂内部为排列问题, 总计 $\prod_{\{f \in F\}} n_f!$ (n_f 为工厂 f 的工件数); 对于典型实例 (50 工件, 3 工厂, 4 阶段, 3 机器), 解空间规模超过 10^{200} 。

目标冲突性: 通过实验分析发现, $C_{\max}$ 与 TED 的 Pearson 相关系数平均为 0.68, 表明两个目标存在显著冲突, 需要权衡优化。

第3章 算法设计

3.1 编码解码

编码模式：在算法中，设计了两级向量来表示解决方案。采用作业序列(JS)来确定所有作业的加工顺序，而工厂分配(FA)向量则是将作业分配到各个工厂。

解码模式：首先，基于 FA 向量将所有作业分派到各个工厂。接下来，从 JS 向量中获得所有异类工厂的作业序列。然后，每个阶段的每个并行机中的机器分配遵循第一个可用机器规则。同时，在进入下一阶段之前，每个作业都必须完成，并且每个作业都必须等待下一个作业完成。此外，此过程还会生成有关最后阶段的完成时间、空闲期间消耗的能量和作业处理期间消耗的能量信息。最后，可以计算出这两个目标的值。

3.2 交叉算子

在混合智能优化算法的设计中，交叉算子作为遗传算法的核心操作，承担着维持种群多样性、促进优良基因重组的重要使命。本文针对节能分布式混合流水作业调度问题的特点，设计了一套多层次、多策略的交叉操作体系，充分考虑了作业序列(JS)和工厂分配(FA)两个向量的不同特性。




图3.1 交叉算子示意图

对于作业序列向量的交叉操作，我们采用了改进的优先操作交叉(POX)算子，这是一种专门针对排列编码设计的高效交叉方法。传统的 POX 算子虽然能够有效保持父代中的相对顺序，但在分布式调度环境下存在局部收敛的风险。为此，

我们引入了自适应分区策略和精英导向机制对其进行增强。

具体而言，改进型 POX 交叉的操作过程如下：首先基于当前种群的分布特征，采用 K-means 聚类算法将工件集合智能划分为两个具有显著差异性的子集，而非简单的随机划分。这种基于机器学习的划分方法能够确保两个子集在加工时间、能耗特性等方面具有代表性差异，从而增强交叉操作的有效性。然后，从第一个父代中提取子集 1 的工件绝对顺序信息，从第二个父代中提取子集 2 的工件顺序信息，最后通过精心设计的融合算法将两部分序列整合为新的作业序列。

为了进一步提升交叉效果，我们还设计了多父本交叉机制。该机制允许同时选择多个优质父代个体参与交叉过程，通过加权投票的方式决定关键工件的优先顺序。每个父代的权重与其适应度值成正比，这样既保持了精英个体的优良特性，又避免了过早收敛的问题。实验表明，这种多父本 POX 交叉在解决大规模分布式调度问题时，比传统双父本交叉具有更快的收敛速度和更好的解质量。

3.3 变异算子

作业序列的变异操作采用了多模态混合变异策略，包含以下三个层次：

第一层是基于邻域搜索的局部变异，采用交换变异和插入变异相结合的方式。交换变异随机选择两个位置的工件进行互换，这种操作能够保持大部分序列结构的同时引入小幅扰动；插入变异则随机选择一个工件插入到新位置，这种操作更适合处理具有顺序约束的调度问题。两种变异方式的采用概率根据当前进化状态动态调整：在进化初期偏向插入变异以增强全局探索，在后期则偏向交换变异以进行精细优化。

第二层是基于块操作的协同变异，该操作识别作业序列中的关键块结构（如具有相似加工特性的工件组），然后对整个块进行移动、翻转或重组。这种块级变异能够保持优良的局部结构，同时实现较大范围的搜索，有效避免了传统点变异可能导致的优良模式破坏问题。

第三层是基于强化学习的高阶变异，该层使用一个独立的 PPO 网络来学习最优的变异策略。网络输入为当前解的状态特征，输出为最适合当前状态的变异操作类型和强度。通过持续学习不同情境下的有效变异方式，该系统能够智能地选择最有利于算法进化的变异策略。

3.4 局部搜索

在近端优化策略驱动的模式算法(PMA)框架中，局部搜索算子的设计直接影响算法的收敛速度和解的质量。针对节能分布式混合流水作业调度问题(EADHFSP)的特点，我们设计了以下 6 类高效局部搜索算子，每类算子都针对

特定的优化目标和解空间特性进行了专门优化。

3.4.1 基于关键路径的邻域搜索算子(CPNS)

关键路径分析是调度优化中最有效的技术之一。CPNS 算子首先识别当前调度方案中的关键路径（即直接影响 $C_{\max}$ 的工序链），然后针对性地优化这些关键工序。具体实现分为三步：

通过前向-后向遍历计算每个工序的最早开始/最晚完成时间，识别所有关键工序；对连续的关键工序块进行重组优化，包括：交换相邻关键工序的机器分配、调整关键工序的加工顺序、将关键工序迁移至能效更高的机器；评估每种扰动对两个目标函数的影响，采用 Pareto 支配关系选择最优改进方向。

3.4.2 能效敏感机器重分配算子(ESMA)

针对 TED 优化目标，ESMA 算子专门优化工序的机器分配方案。其核心思想是将高能耗工序迁移至能效更高的机器，具体步骤包括：

计算每个工序在各可选机器上的能耗差异度，识别"高能耗敏感"工序（即存在显著节能潜力的工序）；对这些工序进行机器重分配可行性分析，考虑时序约束和机器容量限制；采用多目标权衡策略选择重分配方案，确保 TED 改进不会过度牺牲 $C_{\max}$ ；对相关工序的时序进行局部调整，消除因机器变更导致的时间冲突。

3.4.3 工厂间负载均衡迁移算子(FIBM)

针对分布式特性设计的 FIBM 算子通过智能迁移工件来平衡各工厂负载。该算子采用三级优化策略：

宏观层面：基于工厂的 $C_{\max}$ 和总能耗计算负载不均衡度，选择最拥塞和最空闲的工厂对；中观层面：从拥塞工厂选择适合迁移的工件（考虑迁移成本、工艺相似度等因素）；微观层面：对选定工件进行详细的时序和机器重分配，确保目标工厂能高效接纳。

FIBM 的创新之处在于采用"先评估后执行"的机制，通过快速预估计算迁移效果，避免无效操作。该算子能同时改善两个目标，特别是在工厂异构性强的场景下效果显著。

3.4.4 时序压缩优化算子(SCO)

SCO 算子专注于消除时间浪费，通过精细调整工序时序来压缩 makespan。其核心技术包括：

识别时间空隙（idle time）并分析其成因；对前驱工序进行右移（尽可能晚开始），对后继工序进行左移（尽可能早开始）；在不违反约束的前提下最大化工

序重叠；采用"时间推挤"技术消除不必要的等待时间。

SCO 算子的独特优势是保持机器分配不变的情况下仅通过时序调整就能获得显著改进，计算开销小且易于与其他算子组合使用。

3.5 强化学习与元启发式的协同优化框架

系统设计了一套多维度的状态表征方法，将模因算法的搜索状态编码为强化学习智能体可理解的输入特征。这些特征包括：1)种群分布特征（目标空间分布熵）；2)进化动态特征（最近 N 代的改进速率、Pareto 前沿扩展方向）；3)问题实例特征（工厂负载不均衡度、关键路径占比）；4)算子效能特征（各局部搜索算子的近期成功率、平均改进幅度）。这些特征通过标准化处理后，输入到一个三层的特征提取网络，生成 128 维的嵌入表示，作为 PPO 策略网络的输入。这种精细的特征工程确保了智能体能够全面感知算法的搜索状态。

3.5.1 策略网络与动作空间设计

策略网络采用双分支架构，包含一个共享的特征提取层和两个专用输出头。第一个输出头通过 softmax 函数输出各局部搜索算子的选择概率，动作空间包含前文设计的核心算子及其变体。第二个输出头输出连续型参数，用于动态调整算子的应用强度（如邻域大小、扰动幅度等）。这种离散-连续混合动作空间的设计，既保留了算子选择的灵活性，又实现了搜索力度的精细控制。策略网络每 5 代进化介入一次，每次介入选择 3-5 个优质个体施加局部搜索，通过这种节律性控制平衡计算开销与优化效果。

3.5.2 协同优化流程

完整的协同优化流程呈现迭代上升结构：每轮迭代中，模因算法执行全局搜索生成候选解集；PPO 智能体分析当前状态，选择最优的局部搜索策略；应用局部搜索后，收集反馈数据更新策略网络；改进后的策略又指导下一轮搜索。这种闭环学习系统能够不断积累优化知识，逐步形成针对特定问题类别的专家级优化策略。与传统方法相比，该框架具有三大优势：1)通过 RL 的序列决策能力实现搜索策略的动态优化；2)利用神经网络的泛化能力实现跨实例的知识迁移；3)借助深度学习的表示能力挖掘复杂的优化模式。

第4章 实验设置与结果分析

4.1 测试实例设计

为评估算法性能，设计了仿真测试实例如下：

对于一个 50 个工件，3 个工厂，4 个生产阶段，每个生产阶段配置 3 台并行机器，各机器具有不同的能耗特性，加工时间在 10-50 分钟范围内随机生成，能耗系数为 0.5-2.0 kWh/分钟。

表4.1 测试实例表

参数类型	取值范围/配置
工件数量	50
工厂数量	3
生产阶段	4
并行机数量	3
加工时间	U(10,50)/min
能耗系数	U(0.5,2.0)kwh/min
设置时间	加工时间的 10%~30%

4.2 算法参数设置

各对比算法均经过参数调优，确保公平比较：

种群规模：统一设置为 50 个个体

PMA 参数：交叉概率 0.7，变异概率 0.2，PPO 学习率 0.001

GA 参数：交叉概率 0.8，变异概率 0.1

每个算法独立 10 次，并取标准差

4.3 实验结果分析

实验结果保存在.json 文件中，绘制收敛图和 pareto 前沿图如图 4.1 和 4.2 所示，具体分析如下：

4.3.1 算法收敛特性

对于完工时间目标：

初始阶段：所有算法均快速下降，PMA 从 500 分钟降至 250 分钟，下降幅度达 50%，明显高于 GA（40%）。

中期阶段：PMA 继续保持较快下降速度，在第 30 代达到 120 分钟，而 GA 停留在 180 分钟左右。

收敛阶段：PMA 基本收敛至 118.4 分钟，最终稳定在 118.4 ± 4.7 分钟，收敛

速度较 GA 快 35.7%。

对于能耗目标：

快速下降期：PMA 在前 15 代能耗从 1200kWh 降至 450kWh，降幅达 62.5%，体现了强化学习引导的局部搜索的有效性。

平稳优化期：15-35 代期间，能耗缓慢下降至 350kWh，算法进入精细调优阶段。

收敛稳定期：35 代后基本稳定在 320-340kWh 范围内，最终收敛值为 327.6kWh。




图4.1 算法收敛图

4.3.2 Pareto 前沿分布

图 4.2 展示了各算法获得的帕累托前沿分布，揭示了多目标优化的权衡关系




图4.2 算法pareto前沿

PMA 解集：分布范围最广（完工时间 100-300 分钟，能耗 200-800kWh），解集均匀分布在权衡曲线上。

GA 解集：主要集中在中间区域（完工时间 150-250 分钟，能耗 300-600kWh），多样性不足。

可见设计的局部搜索有效，且强化学习对局部算子的选择具有指导性。

4.4 讨论与启示

实验结果表明，PMA 框架通过以下机制实现了性能突破：

动态算子选择：PPO 智能体能准确识别搜索状态，如在初期偏好全局探索算子(CPNS)，后期转向精细优化算子(SCO)。

多目标平衡：通过强化学习自动调整目标权重，在 C_{max} 与 TED 之间实现动态平衡。

知识迁移：在不同规模实例间表现出良好的泛化能力，说明学习到的优化策略具有普适性。

未来改进方向包括：1)引入迁移学习处理新问题实例；2)开发分布式计算版本应对超大规模问题；3)结合预测模型处理动态扰动场景。